



PRA-SKRIPSI

**ANALISIS PREDIKSI HARGA EMAS
MENGUNAKAN ALGORITMA *SUPPORT
VECTOR REGRESSION* DAN *RANDOM
FOREST* BERDASARKAN DATA BPS**

Hanin Fatma Soraya
NPM 20212300020000

DOSEN PEMBIMBING

Budi Nugroho, S.Kom., M.Kom
Hendra Maulana, S.Kom., M.Kom

**KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI
UNIVERSITAS PEMBANGUNAN NASIONAL VETERAN JAWA TIMUR
FAKULTAS ILMU KOMPUTER
PROGRAM STUDI INFORMATIKA
SURABAYA
2025**

DAFTAR ISI

DAFTAR ISI.....	i
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	6
1.3. Tujuan Penelitian.....	6
1.4. Manfaat Penelitian.....	7
BAB II TINJAUAN PUSTAKA.....	10
2.2.1 Emas	12
2.2.2 Prediksi Harga (<i>Time Series</i>).....	14
2.2.3 Data Mining.....	15
2.2.4 <i>Support Vector Regression</i> (SVR)	16
2.2.5 <i>Random Forest Regression</i>	18
2.2.6 Normalisasi Data (<i>Min–Max Scaler</i>).....	21
2.2.6 <i>Bayesian Optimization</i>	22
2.2.7 Matriks Evaluasi Model	24
2.2.8 Streamlit	26
2.3 Kerangka Berpikir	27
BAB III DESAIN DAN IMPLEMENTASI SISTEM	31
3.1 Metode Penelitian.....	31
3.2 Langkah Analisis.....	34
3.3 Desain Sistem.....	45
3.3.1 Arsitektur Sistem.....	45
3.3.2 Alur Kerja Sistem.....	49
DAFTAR PUSTAKA	52

DAFTAR GAMBAR

Tabel 2. 1 Penelitian Terdahulu	10
Tabel 2. 2 Kriteria Evaluasi Prediksi Berdasarkan Nilai MAPE	26
Tabel 3. 1 Deskripsi Variabel Penelitian.....	31
Tabel 3. 2 Data Emas BPS	36
Tabel 3. 3 Contoh Penanganan Missing Value pada Data Harga Emas	38
Tabel 3. 4 Contoh <i>Feature engineering</i> pada Data Harga Emas	39
Tabel 3. 5 Contoh Proses Normalisasi Data Harga Emas	41

DAFTAR GAMBAR

Gambar 2. 1 Tahapan Algoritma SVR	18
Gambar 2. 2 Alur Kerja <i>Random Forest Regression</i>	20
Gambar 2. 3 Bagan Kerangka Penelitian	29
Gambar 3. 1 Prediksi harga emas	33
Gambar 3. 2 Langkah Analisis Penelitian.....	34
Gambar 3. 3 Mock-up Home / Dashboard	46
Gambar 3. 4 Mock Up Hostorical Data.....	46
Gambar 3. 5 MockUp Prediksi Harga Emas	47
Gambar 3. 6 Mock Up Evaluasi Model.....	48
Gambar 3. 7 Mock Up About.....	48
Gambar 3. 8 Flowchart Sistem Prediksi Emas	49

BAB I

PENDAHULUAN

1.1. Latar Belakang

Emas merupakan salah satu komoditas finansial yang memiliki peran strategis dalam sistem investasi global karena dianggap sebagai aset safe-haven yang dapat melindungi nilai kekayaan dari ketidakpastian ekonomi dan tekanan inflasi. Sebagai instrumen yang relatif stabil dalam jangka panjang, emas sering dijadikan pilihan oleh investor ketika pasar mengalami volatilitas atau krisis keuangan karena kemampuannya dalam menjaga nilai riil dari kekayaan (*hedging*), khususnya dalam kondisi ekonomi yang tidak stabil[1]. Beberapa penelitian dalam konteks keuangan global menunjukkan bahwa emas memiliki karakteristik spesial sebagai aset yang dapat melindungi nilai investasi ketika volatilitas pasar meningkat akibat kondisi ekonomi makro yang buruk atau ketidakpastian politik dan finansial.

Pergerakan harga emas dipengaruhi oleh banyak faktor, termasuk kondisi ekonomi makro, kebijakan moneter, nilai tukar mata uang, serta sentimen pasar global dan domestik[2]. Faktor-faktor ini yang kemudian menciptakan sifat non-linear dan volatilitas pada harga emas, sehingga menjadikan prediksi harga emas sebagai suatu masalah yang kompleks dalam analisis data deret waktu. Volatilitas ini bukan hanya tantangan teoritis tetapi juga berdampak langsung terhadap keputusan investasi, strategi manajemen risiko, dan perencanaan keuangan bagi pelaku pasar[3]. Dengan demikian, penelitian yang dapat menghasilkan prediksi yang lebih akurat bukan hanya penting secara akademik tetapi juga memiliki implikasi praktis bagi investor, perencanaan keuangan, dan pembuat kebijakan.

Berdasarkan data rata-rata harga emas di Jakarta yang bersumber dari Badan Pusat Statistik (BPS), harga emas menunjukkan tren kenaikan yang jelas disertai fluktuasi dalam periode pengamatan. Pada awal periode, harga emas tercatat berada pada kisaran Rp1.269.951 per gram pada minggu pertama Januari, kemudian mengalami kenaikan secara bertahap dengan beberapa koreksi harga dalam jangka pendek. Sepanjang tahun pengamatan, harga emas sempat mengalami peningkatan signifikan, khususnya mulai pertengahan hingga akhir tahun, hingga mencapai nilai tertinggi sebesar Rp1.995.432 per gram pada akhir November. Meskipun demikian, terdapat pula periode stagnasi dan penurunan harga dalam jangka pendek, yang

tercermin dari adanya nilai harga yang relatif tetap pada beberapa minggu berturut-turut.

Pola pergerakan tersebut menunjukkan bahwa harga emas tidak bergerak secara linear, melainkan dipengaruhi oleh dinamika pasar yang kompleks. Fluktuasi mingguan yang terjadi mengindikasikan adanya volatilitas jangka pendek, sementara kecenderungan kenaikan harga dalam jangka panjang menunjukkan peran emas sebagai aset lindung nilai. Karakteristik data seperti ini memperkuat bahwa harga emas termasuk dalam kategori data deret waktu yang bersifat non-linear, volatil, dan mengandung pola temporal, sehingga memerlukan pendekatan analisis yang mampu menangkap dinamika tersebut secara akurat. Oleh karena itu, penggunaan metode prediksi berbasis *machine learning* menjadi relevan untuk memodelkan pola harga emas berdasarkan data historis BPS secara lebih adaptif dibandingkan pendekatan statistik konvensional.

Perkembangan teknik pembelajaran mesin (*machine learning*) dan metode data mining menawarkan pendekatan alternatif yang mampu memodelkan hubungan non-linear dan kompleks pada data deret waktu. Salah satu metode yang banyak digunakan dalam prediksi nilai kontinu adalah *Support Vector Regression* (SVR)[4]. SVR merupakan pengembangan dari *Support Vector Machine* yang dirancang untuk masalah regresi dengan prinsip *structural risk minimization*, sehingga mampu menghasilkan model dengan generalisasi yang baik meskipun data memiliki pola non-linear[5]. Keunggulan SVR terletak pada kemampuannya memanfaatkan fungsi kernel untuk memetakan data ke ruang berdimensi lebih tinggi, sehingga pola hubungan yang tidak dapat ditangkap oleh model linear dapat dimodelkan dengan lebih akurat[6]. Berbagai penelitian terdahulu menunjukkan bahwa SVR efektif digunakan dalam prediksi harga emas karena mampu menangani volatilitas dan fluktuasi data historis dengan tingkat kesalahan prediksi yang relatif rendah dibandingkan metode regresi tradisional.

Selain SVR, algoritma *Random Forest Regression* juga banyak diterapkan dalam prediksi harga komoditas, termasuk harga emas. *Random Forest* merupakan metode *ensemble learning* yang membangun sejumlah pohon keputusan (*decision trees*) secara acak dan menggabungkan hasil prediksinya untuk menghasilkan model yang lebih stabil dan akurat[7]. Keunggulan utama *Random Forest* terletak pada kemampuannya dalam menangkap hubungan kompleks antar variabel, mengurangi

risiko *overfitting*, serta memiliki ketahanan yang baik terhadap *noise* dan data yang tidak seimbang[8]. Dalam konteks data harga emas yang fluktuatif dan dipengaruhi oleh berbagai faktor, *Random Forest* dinilai mampu memberikan performa prediksi yang konsisten karena memanfaatkan agregasi dari banyak model pohon keputusan.

Penggunaan *Support Vector Regression* (SVR) dan *Random Forest* secara bersamaan dalam satu penelitian memberikan landasan analitis yang kuat untuk melakukan perbandingan dua pendekatan pembelajaran mesin yang memiliki karakteristik dan mekanisme kerja yang berbeda. SVR merepresentasikan pendekatan berbasis kernel yang dirancang untuk memodelkan hubungan non-linear melalui pemetaan data ke ruang berdimensi lebih tinggi, sehingga mampu menangkap pola kompleks pada data deret waktu dengan fluktuasi tinggi. Sementara itu, *Random Forest* merepresentasikan pendekatan berbasis *ensemble learning* yang mengombinasikan sejumlah pohon keputusan untuk menghasilkan prediksi yang lebih stabil, robust terhadap *noise*, dan relatif tahan terhadap *overfitting*. Perbedaan mendasar dalam prinsip kerja kedua algoritma tersebut menjadikan perbandingan kinerjanya relevan untuk mengevaluasi efektivitas masing-masing metode pada data harga emas yang memiliki karakteristik volatil dan tidak linear.

Perbandingan ini menjadi penting karena hingga saat ini belum terdapat satu algoritma pembelajaran mesin yang dapat dianggap unggul secara universal untuk seluruh jenis data deret waktu, khususnya data harga komoditas seperti emas yang dipengaruhi oleh dinamika pasar dan faktor eksternal yang kompleks. Data harga emas BPS di Jakarta, yang menunjukkan fluktuasi jangka pendek serta kecenderungan tren jangka panjang, memerlukan pendekatan prediktif yang mampu menyeimbangkan akurasi, stabilitas, dan kemampuan generalisasi model. Oleh karena itu, analisis komparatif antara SVR dan *Random Forest* diharapkan dapat memberikan gambaran yang lebih jelas mengenai algoritma yang paling sesuai untuk karakteristik data tersebut.

Dalam upaya meningkatkan objektivitas dan akurasi model prediksi harga emas, pemilihan dan penyetelan parameter algoritma pembelajaran mesin menjadi aspek yang sangat krusial. Penggunaan parameter yang tidak optimal dapat menyebabkan model menghasilkan prediksi yang kurang akurat atau mengalami *overfitting*. Oleh karena itu, diperlukan suatu pendekatan optimasi yang mampu mencari kombinasi parameter terbaik secara efisien dan sistematis. Dalam penelitian

ini, *Bayesian Optimization* digunakan untuk mengoptimalkan parameter pada algoritma *Support Vector Regression* (SVR) dan *Random Forest*, sehingga diharapkan dapat menghasilkan model prediksi harga emas dengan performa yang lebih optimal[9].

Bayesian Optimization merupakan metode optimasi yang dirancang untuk menangani fungsi objektif yang kompleks dan memiliki biaya evaluasi yang tinggi, khususnya pada permasalahan dengan ruang parameter yang besar. Berbeda dengan teknik penyetelan parameter konvensional seperti *grid search* atau *random search* yang bersifat eksploratif dan membutuhkan banyak iterasi, Bayesian Optimization memanfaatkan pendekatan probabilistik untuk menentukan kombinasi parameter yang paling menjanjikan berdasarkan hasil evaluasi sebelumnya. Keunggulan ini menjadikan Bayesian Optimization lebih efisien dan efektif dalam proses *hyperparameter tuning*, terutama pada model pembelajaran mesin yang kompleks[10].

Penerapan *Bayesian Optimization* pada algoritma SVR dan *Random Forest* diharapkan dapat meningkatkan kemampuan kedua model dalam menangkap pola non-linear dan fluktuatif pada data harga emas[11]. Perbandingan performa kedua algoritma yang telah dioptimasi secara optimal menjadi penting untuk menentukan metode yang paling sesuai dalam memodelkan data harga emas yang bersifat volatil. Dengan demikian, penelitian ini tidak hanya membandingkan dua algoritma pembelajaran mesin, tetapi juga mengevaluasi dampak penggunaan teknik optimasi parameter modern terhadap kinerja model prediksi harga emas.

Penelitian oleh Dina Nudia Ahsanah (2022) menjelaskan bahwa emas merupakan instrumen investasi jangka panjang yang memiliki risiko relatif rendah dan berfungsi sebagai *safe-haven* terhadap ketidakpastian ekonomi dan inflasi. Penelitian tersebut menegaskan bahwa harga emas cenderung stabil dan bahkan meningkat dalam jangka panjang, sehingga banyak diminati oleh masyarakat dan investor. Namun demikian, meskipun stabil secara umum, pergerakan harga emas tetap menunjukkan fluktuasi dalam jangka pendek, yang dipengaruhi oleh kondisi ekonomi dan kebijakan moneter. Hal ini menunjukkan bahwa pemahaman terhadap pola pergerakan harga emas sangat penting untuk mendukung pengambilan keputusan investasi yang rasional[1].

Penelitian oleh Ganapa, Choudari, dan Rao (2024) menjelaskan bahwa volatilitas harga emas menimbulkan ketidakpastian bagi investor karena sulit

menentukan waktu yang tepat untuk membeli atau menjual emas. Dalam penelitiannya, penulis menerapkan algoritma *Random Forest Regression* untuk memprediksi harga emas berdasarkan data historis. Hasil penelitian menunjukkan bahwa *Random Forest* mampu menghasilkan prediksi dengan tingkat akurasi yang baik karena sifatnya sebagai metode *ensemble learning* yang menggabungkan banyak pohon keputusan. Penelitian ini menegaskan bahwa *Random Forest* efektif digunakan untuk memodelkan data harga emas yang dipengaruhi oleh banyak faktor dan mengandung noise[12].

Selanjutnya, penelitian oleh Bowen Xie (2025) menjelaskan bahwa prediksi harga emas merupakan permasalahan yang kompleks karena dipengaruhi oleh faktor ekonomi makro, sentimen pasar, dan spekulasi. Dalam kajiannya, Bowen Xie menekankan bahwa model statistik tradisional sering mengalami keterbatasan dalam menangani data harga emas yang bersifat non-linear dan tidak stabil. Oleh karena itu, metode machine learning seperti *Support Vector Regression* (SVR) dan *Random Forest* dinilai lebih unggul karena mampu menangkap pola non-linear dan fluktuasi harga emas secara lebih adaptif. Penelitian ini memperkuat alasan penggunaan SVR dan *Random Forest* dalam prediksi harga emas modern[13].

Penelitian oleh Prabhat Kumar, Puran Singh, dan Sadhana Rana (2024) menjelaskan bahwa meningkatnya minat masyarakat terhadap emas sebagai aset investasi mendorong perlunya model prediksi harga yang akurat. Penelitian tersebut membandingkan beberapa algoritma machine learning, termasuk *Support Vector Regression* (SVR) dan *Random Forest*, dalam memprediksi harga emas berdasarkan data historis dan variabel ekonomi. Hasil penelitian menunjukkan bahwa algoritma berbasis machine learning mampu memberikan hasil prediksi yang lebih baik dibandingkan pendekatan regresi linear, terutama dalam menghadapi volatilitas harga emas yang tinggi[14].

Selain itu, penelitian oleh Gopi Krishna dkk. (2025) menjelaskan bahwa *Random Forest Regression* memiliki keunggulan dalam memproses data keuangan yang kompleks dan dinamis, seperti harga emas, karena kemampuannya dalam menangani data besar, noise, dan hubungan non-linear antar variabel. Penelitian tersebut menekankan bahwa *Random Forest* memberikan prediksi yang lebih stabil dan adaptif dibandingkan model tradisional, sehingga cocok diterapkan pada pasar komoditas yang volatil seperti emas[7].

Kombinasi perbandingan kedua metode SVR yang berbasis kernel dan *Random Forest* yang berbasis ensemble memberikan kesempatan untuk menganalisis secara komprehensif kelebihan dan kekurangan masing-masing algoritma ketika diterapkan pada dataset nyata dari BPS. Hal ini menjadi penting karena tidak ada satu solusi tunggal yang superior untuk semua jenis data deret waktu, terutama yang bersifat volatil dan non-linear. Dengan demikian, penelitian ini bertujuan untuk membangun dan menganalisis model prediksi harga emas di Jakarta berdasarkan data BPS, serta membandingkan kinerja SVR dan *Random Forest* dalam konteks time series data mining. Hasil dari penelitian ini diharapkan memberikan kontribusi praktis baik secara akademik maupun aplikatif, khususnya dalam pengambilan keputusan investasi, perencanaan keuangan, dan strategi manajemen risiko di pasar emas yang volatil.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana kinerja algoritma *Support Vector Regression* (SVR) dan *Random Forest* dalam memprediksi harga emas di Jakarta berdasarkan data BPS?
2. Algoritma manakah antara *Support Vector Regression* (SVR) dan *Random Forest* yang memberikan hasil prediksi lebih akurat pada data harga emas yang bersifat volatil dan non-linear?

1.3. Tujuan Penelitian

Tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis kinerja algoritma *Support Vector Regression* (SVR) dan *Random Forest* dalam memprediksi harga emas di Jakarta berdasarkan data BPS.
2. Menentukan algoritma yang memberikan hasil prediksi paling akurat antara *Support Vector Regression* (SVR) dan *Random Forest* pada data harga emas yang bersifat volatil dan non-linear.

1.4. Batasan Masalah

Agar penelitian ini lebih terarah dan fokus sesuai dengan tujuan yang telah ditetapkan, maka diberikan beberapa batasan masalah sebagai berikut:

1. Data yang digunakan dalam penelitian ini terbatas pada data rata-rata harga emas di pasaran Jakarta yang diperoleh dari Badan Pusat Statistik (BPS) melalui laman resmi BPS.

2. Data harga emas yang dianalisis merupakan data historis berbentuk deret waktu (*time series*) dengan periode dan frekuensi tertentu sesuai ketersediaan data dari BPS.
3. Variabel yang digunakan dalam penelitian ini hanya data historis harga emas, tanpa memasukkan variabel ekonomi makro lain seperti inflasi, suku bunga, nilai tukar, maupun faktor eksternal lainnya.
4. Metode prediksi harga emas yang digunakan dibatasi pada algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression*.
5. Proses optimasi parameter model dibatasi menggunakan metode Bayesian Optimization, tanpa membandingkannya dengan metode optimasi lain seperti *Grid Search* atau *Random Search*.
6. Evaluasi kinerja model dilakukan menggunakan metrik *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE).
7. Sistem yang dikembangkan bersifat prototipe analitik berbasis Streamlit, yang digunakan untuk menampilkan hasil prediksi dan evaluasi model, dan bukan merupakan sistem produksi berskala besar.
8. Hasil prediksi harga emas yang dihasilkan dalam penelitian ini digunakan sebagai bahan analisis dan pendukung pengambilan keputusan, serta tidak dimaksudkan sebagai rekomendasi investasi secara langsung.

1.5. Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1 Manfaat Akademik

Penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan ilmu pengetahuan, khususnya pada bidang data mining dan machine learning, melalui penerapan dan perbandingan algoritma *Support Vector Regression* (SVR) dan *Random Forest* dalam memprediksi harga emas berbasis data deret waktu. Hasil penelitian ini dapat menjadi referensi bagi penelitian selanjutnya yang mengkaji prediksi harga komoditas menggunakan metode pembelajaran mesin dengan data resmi seperti BPS.

2 Manfaat Praktis

Secara praktis, penelitian ini diharapkan dapat memberikan informasi dan wawasan bagi investor, pelaku usaha, dan pemangku kepentingan dalam

memahami pola pergerakan harga emas di Jakarta serta sebagai bahan pertimbangan dalam pengambilan keputusan investasi dan manajemen risiko. Selain itu, hasil penelitian ini juga dapat dimanfaatkan sebagai dasar pengembangan sistem prediksi harga emas berbasis data historis menggunakan metode *machine learning*.

*Halaman ini
sengaja dikosongkan*

BAB II

TINJAUN PUSTAKA

2.1. Penelitian Terdahulu

Penelitian-penelitian yang sudah dilakukan peneliti sebelumnya yang terkait dengan penelitian yang akan dilakukan adalah sebagai berikut.

Tabel 2. 1 Penelitian Terdahulu

No	Profil Pustaka	Metode dan Temuan
1	Judul: <i>Comparison of Support Vector Regression and Random Forest Regression Algorithms on Gold Price Prediction</i> Penulis: Y. Y. Hutagalung dkk. (2023) Identitas Artikel: JUSIKOM PRIMA, Tahun 2023	Metode: Penelitian ini menggunakan algoritma <i>Support Vector Regression</i> (SVR) dan <i>Random Forest Regression</i> untuk memprediksi harga emas berdasarkan data historis harga emas. Proses penelitian meliputi tahap pra-pemrosesan data, pembagian data latih dan data uji, serta pembangunan model prediksi menggunakan kedua algoritma tersebut. Evaluasi performa model dilakukan dengan menggunakan metrik kesalahan regresi, yaitu <i>Mean Absolute Error</i> (MAE) dan <i>Root Mean Square Error</i> (RMSE). Temuan: Hasil penelitian menunjukkan bahwa kedua algoritma mampu memodelkan pergerakan harga emas secara cukup baik. Namun, <i>Random Forest Regression</i> menunjukkan performa yang lebih stabil dan konsisten dibandingkan SVR, khususnya pada data harga emas yang memiliki fluktuasi tinggi. Penelitian ini menyimpulkan bahwa <i>Random Forest</i> lebih robust terhadap variasi data dan noise, sedangkan SVR tetap efektif dalam menangkap pola non-linear pada data harga emas.
2	Judul: <i>Prediksi Harga Emas Menggunakan Support Vector Regression dan Random Forest Regression</i> Penulis: Satyawati, Elisa (2024) Identitas Artikel: Repository Universitas Pelita Harapan, Tahun 2024	Metode: Penelitian ini menerapkan algoritma <i>Support Vector Regression</i> (SVR) dan <i>Random Forest Regression</i> untuk meramalkan harga emas dengan memanfaatkan data historis harga emas. Tahapan penelitian mencakup pembersihan data, normalisasi data, serta penentuan parameter model untuk masing-masing algoritma. Model yang dihasilkan kemudian diuji menggunakan data uji untuk melihat kemampuan generalisasi model.

No	Profil Pustaka	Metode dan Temuan
		Temuan: Hasil penelitian menunjukkan bahwa kedua algoritma mampu memberikan hasil prediksi yang cukup akurat. Perbedaan performa prediksi dipengaruhi oleh karakteristik data, jumlah data latih, serta parameter yang digunakan pada masing-masing algoritma. Penelitian ini menegaskan bahwa pemilihan parameter yang tepat memiliki pengaruh signifikan terhadap tingkat akurasi model prediksi harga emas.
3	Judul: <i>Perbandingan Kinerja GRU dan SVR untuk Prediksi Emas di Indonesia</i> Penulis: Mohammad Sufa Ammar Habibi dkk. (2025) Identitas Artikel: Jurnal Teknologi Informasi, Tahun 2025	Metode: Penelitian ini menggunakan algoritma <i>Support Vector Regression</i> (SVR) dan Gated Recurrent Unit (GRU) untuk memprediksi harga emas di Indonesia berdasarkan data historis. SVR digunakan sebagai metode pembandingan terhadap model deep learning GRU. Evaluasi performa dilakukan menggunakan metrik kesalahan prediksi untuk menilai tingkat akurasi masing-masing model. Temuan: Hasil penelitian menunjukkan bahwa SVR memiliki performa yang stabil dan kompetitif dalam memprediksi harga emas, terutama pada data deret waktu yang tidak memiliki fluktuasi ekstrem. Meskipun GRU mampu menangkap pola temporal yang kompleks, SVR tetap menunjukkan keunggulan dari sisi kesederhanaan model dan efisiensi komputasi. Penelitian ini memperkuat relevansi SVR sebagai metode prediksi harga emas berbasis data historis.
4	Judul: <i>Gold Price Forecasting Using Machine Learning Techniques</i> Penulis: P. Kumar, P. Singh, dan S. Rana (2024) Identitas Artikel: International Journal of Computer Applications, Tahun 2024	Metode: Penelitian ini membandingkan beberapa algoritma <i>machine learning</i> untuk memprediksi harga emas, termasuk <i>Support Vector Regression</i> dan <i>Random Forest</i>. Data yang digunakan merupakan data historis harga emas dengan karakteristik non-linear. Proses penelitian mencakup analisis data, pembangunan model prediksi, serta evaluasi performa menggunakan metrik kesalahan prediksi. Temuan: Hasil penelitian menunjukkan bahwa algoritma berbasis <i>machine learning</i>, khususnya SVR dan <i>Random Forest</i>, memberikan performa yang lebih

No	Profil Pustaka	Metode dan Temuan
		baik dibandingkan metode statistik tradisional. Kedua algoritma dinilai mampu menangkap pola non-linear pada data harga emas, sehingga menghasilkan prediksi yang lebih akurat dan adaptif terhadap perubahan tren harga.
5	Judul: <i>Gold Price Prediction Using Random Forest Regression</i> Penulis: Gopi Krishna dkk. (2025) Identitas Artikel: ETE Journal, Tahun 2025	Metode: Penelitian ini secara khusus menggunakan algoritma <i>Random Forest Regression</i> untuk memprediksi harga emas berdasarkan data historis. Model dibangun dengan menggabungkan sejumlah pohon keputusan (<i>decision trees</i>) dan memanfaatkan mekanisme <i>ensemble learning</i> untuk meningkatkan akurasi dan stabilitas prediksi. Evaluasi model dilakukan menggunakan beberapa metrik kesalahan regresi. Temuan: Hasil penelitian menunjukkan bahwa <i>Random Forest Regression</i> mampu menghasilkan prediksi harga emas yang akurat dan memiliki ketahanan yang baik terhadap noise dalam data. Model ini dinilai efektif dalam menangani fluktuasi harga emas yang tinggi, sehingga cocok diterapkan pada data harga emas yang bersifat volatil dan kompleks.

2.2. Dasar Teori

2.2.1 Emas

Emas merupakan salah satu logam mulia yang telah digunakan oleh manusia sejak ribuan tahun lalu, baik sebagai alat tukar, perhiasan, maupun simbol kekayaan. Secara historis, emas pernah digunakan sebagai standar moneter (*gold standard*) yang menjadi dasar sistem keuangan di berbagai negara, karena sifatnya yang langka, tahan lama, dan memiliki nilai yang relatif stabil. Meskipun sistem moneter modern tidak lagi berbasis emas secara langsung, peran emas sebagai aset bernilai tinggi tetap bertahan hingga saat ini, khususnya dalam konteks investasi dan penyimpanan nilai (*store of value*)[15].

Dalam sistem keuangan modern, emas dikenal sebagai aset *safe-haven* karena kemampuannya mempertahankan nilai pada saat terjadi ketidakpastian ekonomi, inflasi, krisis keuangan, maupun gejolak pasar. Ketika nilai mata uang melemah atau pasar saham mengalami tekanan, investor cenderung mengalihkan asetnya ke emas sebagai bentuk perlindungan terhadap risiko.

Oleh karena itu, emas sering dijadikan alternatif investasi jangka panjang yang relatif aman dibandingkan instrumen keuangan lain yang lebih sensitif terhadap fluktuasi pasar.

Harga emas dipengaruhi oleh berbagai faktor, baik global maupun domestik, sehingga pergerakannya cenderung bersifat fluktuatif. Faktor-faktor tersebut meliputi kondisi ekonomi makro, tingkat inflasi, kebijakan moneter dan suku bunga, nilai tukar mata uang, serta sentimen pasar dan kondisi geopolitik. Interaksi antar faktor tersebut menyebabkan harga emas tidak bergerak secara linear dan sering menunjukkan volatilitas yang cukup tinggi dalam jangka pendek, meskipun dalam jangka panjang cenderung membentuk tren tertentu. Karakteristik ini menjadikan harga emas sebagai data deret waktu (*time series*) yang kompleks dan menantang untuk dianalisis serta diprediksi secara akurat[16].

Di Indonesia, emas memiliki peran penting dalam aktivitas investasi masyarakat, baik dalam bentuk perhiasan, emas batangan, maupun instrumen investasi berbasis emas. Pergerakan harga emas menjadi perhatian bagi investor individu maupun pelaku ekonomi karena sering dijadikan indikator kondisi ekonomi dan stabilitas keuangan. Data resmi mengenai rata-rata harga emas, khususnya di Jakarta, disediakan oleh Badan Pusat Statistik (BPS) dan digunakan sebagai acuan dalam analisis ekonomi serta penelitian berbasis data. Data harga emas dari BPS mencerminkan dinamika pasar emas domestik yang dipengaruhi oleh kondisi ekonomi nasional maupun global, serta kebijakan ekonomi yang berlaku di Indonesia.

Sebagai data deret waktu, harga emas memiliki karakteristik pola non-linear, volatilitas yang berubah-ubah, serta dipengaruhi oleh banyak faktor eksternal yang saling berinteraksi. Karakteristik tersebut menuntut penggunaan metode analisis yang mampu menangkap dinamika perubahan harga secara adaptif dan fleksibel. Metode statistik konvensional sering kali memiliki keterbatasan dalam memodelkan hubungan yang kompleks dan non-linear pada data harga emas[17]. Oleh karena itu, pendekatan berbasis *machine learning* menjadi relevan untuk digunakan dalam memodelkan dan memprediksi harga emas berdasarkan data historis, karena mampu menangkap

pola yang lebih kompleks serta menyesuaikan diri terhadap perubahan tren harga dari waktu ke waktu.

2.2.2 Prediksi Harga (*Time Series*)

Prediksi harga merupakan suatu proses untuk memperkirakan nilai suatu variabel pada masa yang akan datang berdasarkan pola dan informasi yang terkandung dalam data historis[18]. Dalam bidang ekonomi dan keuangan, prediksi harga memiliki peranan penting sebagai dasar dalam pengambilan keputusan investasi, perencanaan strategi bisnis, serta pengelolaan risiko. Ketepatan hasil prediksi sangat berpengaruh terhadap kualitas keputusan yang diambil, sehingga diperlukan pendekatan analitis yang mampu menghasilkan estimasi harga yang akurat dan dapat diandalkan. Salah satu jenis data yang paling umum digunakan dalam prediksi harga adalah data deret waktu (*time series*), yaitu data yang dikumpulkan secara berurutan berdasarkan interval waktu tertentu, seperti harian, mingguan, atau bulanan[19].

Data deret waktu memiliki karakteristik khusus yang membedakannya dari data statis. Karakteristik tersebut meliputi adanya ketergantungan nilai saat ini terhadap nilai pada periode sebelumnya (*temporal dependency*), keberadaan pola tren jangka panjang, pola musiman, serta fluktuasi acak (*noise*). Selain itu, data deret waktu sering kali dipengaruhi oleh perubahan struktural yang menyebabkan pola pergerakan data tidak selalu konsisten dari waktu ke waktu. Pada data harga komoditas seperti emas, karakteristik tersebut semakin menonjol karena harga dipengaruhi oleh dinamika pasar global dan kondisi ekonomi yang terus berubah[20].

Dalam prediksi harga emas, data historis digunakan untuk mengidentifikasi pola pergerakan harga dari waktu ke waktu dengan tujuan memperkirakan harga pada periode selanjutnya. Namun, pergerakan harga emas tidak hanya ditentukan oleh pola historis semata, melainkan juga dipengaruhi oleh berbagai faktor eksternal seperti kondisi ekonomi makro, kebijakan moneter, inflasi, tingkat suku bunga, serta sentimen pasar dan kondisi geopolitik. Faktor-faktor tersebut dapat menyebabkan perubahan pola secara tiba-tiba, sehingga model prediksi harus memiliki kemampuan untuk beradaptasi terhadap dinamika perubahan tersebut[17]. Oleh karena itu, model

prediksi yang baik tidak hanya mampu mengikuti tren jangka panjang, tetapi juga responsif terhadap fluktuasi jangka pendek yang terjadi pada data harga.

Selain itu, prediksi harga deret waktu juga dipengaruhi oleh horizon prediksi yang digunakan, yaitu jangka waktu ke depan yang ingin diprediksi, baik jangka pendek, menengah, maupun jangka panjang. Prediksi jangka pendek umumnya lebih sensitif terhadap fluktuasi dan *noise*, sedangkan prediksi jangka panjang lebih dipengaruhi oleh tren umum data. Perbedaan horizon prediksi ini menuntut model yang memiliki keseimbangan antara kemampuan mengikuti pola historis dan kemampuan generalisasi terhadap data baru.

Pendekatan konvensional dalam prediksi deret waktu umumnya menggunakan metode statistik seperti regresi linier atau model autoregresif. Metode-metode tersebut efektif ketika data memiliki pola yang relatif stabil dan linear. Namun, keterbatasan metode statistik tradisional menjadi jelas ketika dihadapkan pada data yang bersifat non-linear, memiliki volatilitas tinggi, dan dipengaruhi oleh banyak faktor eksternal seperti harga emas[21]. Dalam konteks ini, metode pembelajaran mesin (*machine learning*) menawarkan pendekatan yang lebih fleksibel karena mampu mempelajari pola kompleks dan non-linear dari data historis tanpa memerlukan asumsi linearitas yang ketat. Dengan kemampuannya dalam menangkap hubungan yang lebih kompleks, pendekatan *machine learning* menjadi relevan untuk digunakan dalam prediksi harga berbasis *time series*, khususnya pada data harga emas yang dinamis dan fluktuatif.

2.2.3 Data Mining

Menurut Han, J., Kamber, M., dan Pei, J. (2011), data mining, atau yang dikenal sebagai *knowledge discovery from data* (KDD), adalah suatu proses untuk mengekstrak pola-pola yang mewakili pengetahuan yang tersimpan atau tertangkap dalam basis data besar, gudang data, atau repositori informasi lainnya. data mining juga merupakan bidang multidisipliner yang menggabungkan teknik dari statistik, pembelajaran mesin, pengenalan pola, teknologi basis data, dan banyak disiplin ilmu lainnya[22]. Teknik yang biasa digunakan dalam data mining adalah pengenalan pola, pengelompokan, asosiasi, prediksi, dan klasifikasi. Proses

data mining sendiri bertujuan untuk mengubah sejumlah besar data menjadi menjadi sebuah pola atau model yang memiliki hasil akurasi yang dapat dipercaya[23]. Dalam prosesnya, tentunya *data mining* memiliki tahapan-tahapan agar proses *data mining* dapat memperoleh hasil sesuai target. Dalam prosesnya memiliki beberapa tahapan yaitu:

1. Seleksi Data (*Selection*)

Sebelum melaksanakan penggalian data, langkah awal yang dilakukan yaitu menyeleksi kumpulan data atau informasi yang ada[24].

2. *Cleaning/ Pre-processing*

Data yang digunakan sebagai fokus pada KDD harus dibersihkan terlebih dahulu terutama seperti data yang ganda, data tidak konsisten dan perbaikan data yang mengalami kerusakan atau kesalahan[24].

3. Transformasi Data (*Transformation*)

Agar data dapat diolah pada tahap berikutnya, data terlebih dahulu diubah melalui proses pengkodean[24].

4. Penggalian Data (Data Mining)

Penggalian data yaitu tahapan-tahapan yang menerapkan suatu metode yang bertujuan memperoleh informasi atau pola yang dibutuhkan pada kumpulan data yang sudah dipilih[24].

5. Interpretation/ Evaluation

Pada tahap ini, proses *data mining* menghasilkan suatu alur data dan informasi yang kemudian ditampilkan ke dalam bentuk mudah dimengerti oleh pihak terkait[24].

2.2.4 Support Vector Regression (SVR)

Support Vector Regression (SVR) merupakan pengembangan dari *Support Vector Machine* (SVM) yang digunakan untuk menyelesaikan permasalahan regresi, yaitu prediksi nilai kontinu. SVR bekerja dengan prinsip *structural risk minimization*, yang bertujuan untuk memperoleh model dengan tingkat kesalahan generalisasi yang rendah[25]. Berbeda dengan regresi linier yang berfokus pada meminimalkan kesalahan total, SVR berusaha mencari fungsi regresi

terbaik dengan mempertahankan margin kesalahan tertentu yang masih dapat ditoleransi.

Konsep utama dalam SVR adalah penggunaan fungsi ε -insensitive loss, yaitu kesalahan prediksi yang masih berada dalam batas toleransi ε tidak akan diperhitungkan sebagai kesalahan. Dengan pendekatan ini, SVR mampu mengabaikan fluktuasi kecil (*noise*) pada data, sehingga menghasilkan model yang lebih stabil[26]. Model SVR dibangun dengan memanfaatkan sejumlah titik data terpilih yang disebut *support vectors*, yaitu data-data yang berada di luar atau tepat pada batas margin dan memiliki pengaruh besar terhadap pembentukan fungsi regresi.

Salah satu keunggulan utama SVR terletak pada kemampuannya dalam menangani hubungan non-linear melalui penggunaan fungsi kernel. Fungsi kernel memungkinkan data dipetakan ke ruang berdimensi lebih tinggi sehingga hubungan non-linear pada ruang asli dapat dimodelkan secara linear pada ruang hasil pemetaan. Beberapa jenis fungsi kernel yang umum digunakan pada SVR antara lain kernel linear, polynomial, dan Radial Basis Function (RBF). Pemilihan kernel yang tepat sangat berpengaruh terhadap kemampuan model dalam menangkap pola data.

Secara umum, SVR berusaha mencari suatu fungsi regresi:

$$f(x) = w^T x + b$$

di mana:

f adalah vektor data input,


w adalah vektor bobot,

b adalah bias,

$f(x)$ adalah nilai prediksi.

Berbeda dengan regresi linier biasa, SVR menggunakan konsep ε -insensitive loss function, yaitu kesalahan prediksi yang berada dalam batas toleransi ε tidak dianggap sebagai kesalahan. Dengan demikian, SVR berusaha membentuk sebuah “tabung” (ε -tube) di sekitar fungsi regresi, di mana data yang berada di dalam tabung tersebut tidak dikenakan penalti.

SVR memiliki kelebihan dalam menangani data non-linear dan menghasilkan model dengan kemampuan generalisasi yang baik, terutama pada data deret waktu dengan fluktuasi tinggi seperti harga emas[14]. Namun, SVR juga memiliki keterbatasan, yaitu sensitivitas terhadap pemilihan parameter dan kebutuhan komputasi yang relatif tinggi jika jumlah data besar. Oleh karena itu, diperlukan teknik optimasi parameter, seperti Bayesian Optimization, untuk memperoleh performa model yang optimal. Berikut *Flowchart* dari alur kerja algoritma SVR



Gambar 2. 1 Tahapan Algoritma SVR

Flowchart ini menunjukkan tahapan kerja *Support Vector Regression* dalam membangun model prediksi harga emas, mulai dari data historis hingga terbentuknya model regresi berbasis *support vectors*.

2.2.5 Random Forest Regression

Random Forest Regression merupakan salah satu algoritma *machine learning* berbasis ensemble learning yang digunakan untuk menyelesaikan permasalahan regresi[27]. Algoritma ini dikembangkan dari metode

decision tree dengan cara menggabungkan banyak pohon keputusan (*trees*) untuk menghasilkan prediksi yang lebih stabil dan akurat. Istilah *Random Forest* merujuk pada kumpulan pohon keputusan yang dibangun secara acak dan independen, kemudian hasil prediksinya digabungkan untuk menghasilkan satu nilai prediksi akhir.

Prinsip utama *Random Forest* adalah mengurangi kelemahan *decision tree* tunggal yang cenderung mengalami *overfitting*. Pada *Random Forest*, setiap pohon dibangun menggunakan subset data latih yang dipilih secara acak melalui teknik *bootstrap sampling*. Selain itu, pada setiap proses pemisahan node, hanya sebagian fitur yang dipilih secara acak untuk menentukan pemisahan terbaik. Proses randomisasi ini membuat setiap pohon memiliki struktur yang berbeda, sehingga kesalahan prediksi dari satu pohon dapat dikompensasi oleh pohon lainnya[9].

Secara umum, proses kerja *Random Forest Regression* dapat dijelaskan melalui tahapan berikut:

1. Bootstrap Sampling

Random Forest mengambil sejumlah sampel data secara acak dari dataset asli menggunakan metode *bootstrap sampling*, yaitu pengambilan sampel dengan pengembalian (*sampling with replacement*). Setiap sampel bootstrap digunakan untuk membangun satu pohon keputusan yang berbeda.

2. Pembangunan Pohon Keputusan

Untuk setiap sampel data hasil bootstrap, dibangun sebuah pohon keputusan (*decision tree*) tanpa melakukan proses pemangkasan (*pruning*). Hal ini bertujuan agar setiap pohon dapat mempelajari pola data secara maksimal.

3. Pemilihan Fitur Secara Acak

Pada setiap node pohon keputusan, *Random Forest* tidak menggunakan seluruh fitur yang tersedia, melainkan memilih sebagian fitur secara acak (*random feature selection*) untuk menentukan pemisahan terbaik. Proses ini meningkatkan keragaman antar pohon dan mengurangi korelasi antar model.


4. Pembentukan Hutan Pohon

Proses pembangunan pohon keputusan diulang hingga terbentuk sejumlah pohon sesuai dengan parameter jumlah pohon (*number of trees*). Kumpulan pohon keputusan ini disebut sebagai *forest*.

5. Agregasi Hasil Prediksi

Setiap pohon keputusan menghasilkan satu nilai prediksi. Hasil prediksi akhir *Random Forest Regression* diperoleh dengan menggabungkan seluruh prediksi pohon menggunakan nilai rata-rata (*averaging*), sehingga menghasilkan prediksi yang lebih stabil dan akurat.

Berikut alur kerja *Random Forest Regression*



Gambar 2. 2 Alur Kerja *Random Forest Regression*

Secara matematis, prediksi *Random Forest Regression* dapat dirumuskan sebagai berikut:

$$\gamma = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

dengan keterangan:

γ : nilai prediksi akhir,

T : jumlah pohon keputusan (*number of trees*),

$h_t(x)$: hasil prediksi dari pohon keputusan ke- t terhadap data input x

Rumus tersebut menunjukkan bahwa nilai prediksi akhir *Random Forest Regression* diperoleh dari rata-rata hasil prediksi seluruh pohon keputusan. Pendekatan ini membuat model *Random Forest* lebih tahan terhadap *noise* dan mengurangi risiko *overfitting* dibandingkan dengan penggunaan satu pohon keputusan tunggal[12].

2.2.6 Normalisasi Data (*Min–Max Scaler*)

Normalisasi data merupakan salah satu tahap penting dalam pra-pemrosesan data (*data preprocessing*) yang bertujuan untuk menyamakan skala nilai antar fitur dalam suatu dataset[28]. Pada data numerik, perbedaan skala yang terlalu besar antar variabel dapat memengaruhi kinerja algoritma pembelajaran mesin, khususnya algoritma yang sensitif terhadap jarak dan besaran nilai, seperti *Support Vector Regression* (SVR). Oleh karena itu, normalisasi data diperlukan agar setiap fitur memiliki kontribusi yang seimbang dalam proses pembentukan model.

Salah satu metode normalisasi yang umum digunakan adalah *Min–Max Scaler*. Metode ini melakukan transformasi data dengan mengubah nilai asli suatu fitur ke dalam rentang tertentu, biasanya antara 0 hingga 1. Dengan menggunakan *Min–Max Scaler*, hubungan relatif antar nilai dalam data tetap dipertahankan, namun perbedaan skala antar fitur dapat diminimalkan[29]. Hal ini sangat penting dalam pemodelan prediksi harga emas yang menggunakan data deret waktu dengan rentang nilai harga yang besar.

Secara matematis, proses normalisasi menggunakan *Min–Max Scaler* dirumuskan sebagai berikut:

$$x = \frac{x - x_{min}}{x_{max} - x_{min}}$$

dengan keterangan:

- x : nilai data asli,
- x : nilai data hasil normalisasi,
- x_{min} : nilai minimum dari fitur,
- x_{max} : nilai maksimum dari fitur.

Hasil transformasi tersebut akan menghasilkan nilai data yang berada pada rentang 0 hingga 1. Dalam konteks prediksi harga emas, normalisasi dengan Min–Max Scaler membantu model SVR dalam menghitung jarak antar data secara lebih proporsional dan mempercepat proses konvergensi model. Meskipun *Random Forest* relatif tidak sensitif terhadap skala data, penerapan normalisasi tetap dilakukan untuk menjaga konsistensi pra-pemrosesan data dan memastikan seluruh algoritma diperlakukan secara seragam.

Dengan demikian, normalisasi data menggunakan Min–Max Scaler merupakan langkah pra-pemrosesan yang penting dalam penelitian ini untuk meningkatkan stabilitas dan kinerja model prediksi harga emas, terutama ketika menggunakan algoritma berbasis jarak dan kernel seperti Support Vector Regression.

2.2.6 Bayesian Optimization

Bayesian Optimization merupakan metode optimasi yang digunakan untuk mencari nilai parameter terbaik dari suatu fungsi objektif yang kompleks, mahal untuk dievaluasi, dan tidak memiliki bentuk analitik yang sederhana[30]. Dalam konteks *machine learning*, *Bayesian Optimization* banyak digunakan untuk melakukan penyetelan parameter (*hyperparameter tuning*) pada model prediksi, khususnya ketika ruang parameter yang dieksplorasi cukup besar dan proses pelatihan model membutuhkan waktu komputasi yang tinggi.

Berbeda dengan metode optimasi konvensional seperti *grid search* dan *random search* yang mencoba kombinasi parameter secara eksplisit dan cenderung membutuhkan banyak iterasi, *Bayesian Optimization* menggunakan pendekatan probabilistik untuk menentukan kombinasi parameter yang paling menjanjikan[31]. Metode ini membangun suatu model probabilistik yang disebut *surrogate model* untuk merepresentasikan fungsi objektif, kemudian menggunakan informasi tersebut untuk menentukan titik evaluasi berikutnya secara efisien.

Secara umum, *Bayesian Optimization* bekerja dengan memodelkan hubungan antara parameter dan nilai fungsi objektif menggunakan model probabilistik, seperti *Gaussian Process*. Model ini memberikan estimasi nilai fungsi objektif beserta tingkat ketidakpastiannya. Berdasarkan informasi tersebut, Bayesian

Optimization menentukan parameter selanjutnya yang akan dievaluasi dengan memaksimalkan fungsi akuisisi (*acquisition function*).

Proses Bayesian Optimization dapat dirangkum dalam tahapan berikut:

1. Menentukan ruang parameter (*search space*) yang akan dioptimasi.
2. Memilih model probabilistik sebagai *surrogate model*.
3. Mengevaluasi beberapa titik awal parameter secara acak.
4. Memperbarui *surrogate model* berdasarkan hasil evaluasi.
5. Menentukan parameter berikutnya menggunakan fungsi akuisisi.
6. Mengulangi proses hingga kriteria penghentian terpenuhi.

Fungsi akuisisi berperan penting dalam menentukan keseimbangan antara eksplorasi dan eksploitasi. Eksplorasi bertujuan untuk mencoba area parameter yang belum banyak dievaluasi, sedangkan eksploitasi berfokus pada area yang diperkirakan memberikan nilai fungsi objektif terbaik. Salah satu fungsi akuisisi yang umum digunakan adalah *Expected Improvement* (EI), yang dirumuskan sebagai:

$$EI(x) = E[\max(f(x) - f(x^+), 0)]$$

di mana $f(x^+)$ merupakan nilai fungsi objektif terbaik yang telah diperoleh sebelumnya.

Dalam penelitian ini, *Bayesian Optimization* digunakan untuk mengoptimalkan parameter pada algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression*. Pada SVR, parameter yang dioptimasi meliputi parameter penalti CCC, parameter toleransi kesalahan ϵ , serta parameter kernel seperti γ . Sementara itu, pada *Random Forest*, parameter yang dioptimasi meliputi jumlah pohon ($n_estimators$), kedalaman maksimum pohon (max_depth), dan jumlah fitur yang digunakan pada setiap pemisahan ($max_features$).

Penggunaan *Bayesian Optimization* memungkinkan pencarian kombinasi parameter yang optimal secara lebih efisien dibandingkan metode konvensional, sehingga diharapkan mampu meningkatkan akurasi dan stabilitas model prediksi harga emas. Dengan demikian, *Bayesian Optimization* menjadi pembaruan metodologis (*novelty*) dalam penelitian ini karena tidak hanya membandingkan dua algoritma pembelajaran mesin, tetapi juga mengoptimalkan kinerja masing-masing algoritma menggunakan pendekatan optimasi modern berbasis probabilistik.

Bayesian Optimization memiliki beberapa keunggulan, antara lain:

- 1 Lebih efisien dalam mengeksplorasi ruang parameter yang besar.
- 2 Mengurangi jumlah evaluasi fungsi objektif yang mahal secara komputasi.
- 3 Mampu menghasilkan model dengan performa yang lebih optimal dan stabil.

Oleh karena itu, penerapan *Bayesian Optimization* dalam penelitian ini diharapkan dapat meningkatkan kualitas prediksi harga emas dan memberikan kontribusi metodologis dalam penerapan *machine learning* pada prediksi harga komoditas.

2.2.7 Matriks Evaluasi Model

Untuk memperoleh model prediksi yang efektif dan akurat, diperlukan proses evaluasi model menggunakan metrik evaluasi yang sesuai dengan permasalahan regresi. Evaluasi model bertujuan untuk mengukur tingkat kesalahan prediksi yang dihasilkan oleh model terhadap nilai aktual[32]. Pada penelitian ini, metrik evaluasi yang digunakan meliputi *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE).

1) *Mean Absolute Error* (MAE)

Mean Absolute Error (MAE) merupakan metrik evaluasi yang digunakan dalam analisis regresi untuk mengukur rata-rata kesalahan absolut antara nilai prediksi yang dihasilkan oleh model dan nilai aktual[33]. MAE memberikan gambaran seberapa besar kesalahan prediksi model dalam satuan yang sama dengan variabel yang diprediksi, sehingga mudah untuk diinterpretasikan.

Secara matematis, MAE dirumuskan sebagai berikut:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

dengan keterangan:

n : jumlah data dalam dataset,

y_i : nilai aktual pada data ke- i ,

$\hat{y}_i$: nilai prediksi pada data ke- i .

Semakin kecil nilai MAE, maka semakin baik kinerja model prediksi karena menunjukkan bahwa rata-rata kesalahan prediksi semakin mendekati nol.

2) *Root Mean Square Error* (RMSE)

Root Mean Square Error (RMSE) merupakan metrik evaluasi yang digunakan untuk mengukur besarnya kesalahan prediksi model dengan memberikan penalti

yang lebih besar terhadap kesalahan yang bernilai besar[34]. RMSE sangat sensitif terhadap *outlier* karena kesalahan dikuadratkan sebelum dirata-ratakan.

RMSE dirumuskan sebagai berikut:

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

dengan keterangan:

n : jumlah data,

y_i : nilai aktual,

$\hat{y}_i$: nilai prediksi hasil model.

Nilai RMSE yang lebih kecil menunjukkan bahwa hasil prediksi model semakin mendekati nilai aktual. RMSE sering digunakan untuk membandingkan performa beberapa model prediksi karena mampu menyoroti kesalahan besar yang terjadi pada prediksi.

3) Mean Absolute Percentage Error (MAPE)

Mean Absolute Percentage Error (MAPE) merupakan metrik evaluasi yang mengukur rata-rata persentase kesalahan absolut antara nilai prediksi dan nilai aktual[35]. MAPE dinyatakan dalam bentuk persentase, sehingga lebih mudah dipahami dan digunakan untuk membandingkan kinerja beberapa model prediksi.

MAPE dirumuskan sebagai berikut:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

dengan keterangan:

y_i : nilai aktual pada periode ke- i ,

$\hat{y}_i$: nilai prediksi pada periode ke- i ,

n : jumlah periode pengamatan.

MAPE menghasilkan nilai dalam bentuk persentase, di mana nilai yang lebih kecil menunjukkan tingkat kesalahan prediksi yang lebih rendah dan akurasi model yang lebih baik. Klasifikasi tingkat akurasi prediksi berdasarkan nilai MAPE dapat dilihat pada Tabel 2.3.

Tabel 2. 2 Kriteria Evaluasi Prediksi Berdasarkan Nilai MAPE

Nilai MAPE	Tingkat Akurasi Prediksi
$MAPE \leq 10\%$	Sangat Baik
$10\% < MAPE \leq 20\%$	Baik
$20\% < MAPE \leq 50\%$	Cukup Baik
$MAPE > 50\%$	Kurang Baik

Kelebihan MAPE terletak pada kemudahan interpretasinya karena dinyatakan dalam bentuk persentase. Namun, MAPE memiliki kelemahan, yaitu sangat sensitif terhadap nilai aktual yang mendekati nol, sehingga dapat menghasilkan nilai kesalahan yang sangat besar. Oleh karena itu, pada penelitian ini MAPE digunakan bersama dengan MAE dan RMSE agar evaluasi kinerja model prediksi dapat dilakukan secara lebih komprehensif.

2.2.8 Streamlit

Streamlit merupakan sebuah *open-source framework* berbasis Python yang dirancang untuk mempermudah pembuatan aplikasi web interaktif, khususnya dalam bidang *data science* dan *machine learning*[36]. Streamlit memungkinkan peneliti dan pengembang untuk membangun antarmuka pengguna (*user interface*) secara cepat tanpa harus memiliki keahlian khusus dalam pengembangan web seperti HTML, CSS, atau JavaScript. Dengan pendekatan ini, fokus pengembangan dapat diarahkan langsung pada proses analisis data dan pemodelan.

Streamlit bekerja dengan prinsip eksekusi skrip Python secara langsung, di mana setiap perubahan pada kode akan secara otomatis memperbarui tampilan aplikasi. Komponen antarmuka seperti tombol, grafik, tabel, dan input pengguna disediakan dalam bentuk fungsi Python yang sederhana[37]. Hal ini menjadikan Streamlit sangat sesuai digunakan sebagai media visualisasi dan implementasi prototipe sistem analitik berbasis *machine learning*.

Dalam konteks penelitian ini, Streamlit digunakan sebagai media implementasi sistem prediksi harga emas yang telah dibangun menggunakan *algoritma Support Vector Regression (SVR)* dan *Random Forest Regression*. Streamlit berperan sebagai sarana untuk menampilkan data harga emas, hasil prediksi model, serta evaluasi kinerja model dalam bentuk visual yang mudah dipahami. Dengan

demikian, pengguna dapat berinteraksi langsung dengan sistem untuk melihat hasil analisis dan prediksi secara informatif[38].

Penggunaan Streamlit dalam penelitian akademik memiliki beberapa keunggulan. Pertama, Streamlit memungkinkan integrasi langsung dengan pustaka *machine learning* Python seperti *scikit-learn*, *NumPy*, dan *Pandas*, sehingga proses pemodelan dan visualisasi dapat dilakukan dalam satu lingkungan pengembangan. Kedua, Streamlit mendukung penyajian hasil penelitian secara interaktif, yang dapat membantu dalam proses analisis dan interpretasi hasil. Ketiga, Streamlit bersifat ringan dan mudah dikonfigurasi, sehingga cocok digunakan sebagai prototipe sistem pendukung keputusan berbasis data.

Meskipun demikian, Streamlit tidak dirancang sebagai *production-level web framework* seperti Flask atau Django. Oleh karena itu, dalam penelitian ini Streamlit digunakan sebagai prototipe sistem analitik, bukan sebagai sistem informasi berskala besar. Pendekatan ini sejalan dengan tujuan penelitian yang berfokus pada pengembangan dan evaluasi model prediksi harga emas, sementara sistem hanya berperan sebagai media pendukung untuk menampilkan hasil prediksi dan evaluasi model secara visual.

2.3 Kerangka Berpikir


Harga emas merupakan salah satu indikator penting dalam aktivitas investasi karena perannya sebagai aset lindung nilai (*safe-haven*). Di Indonesia, khususnya Jakarta, pergerakan harga emas menunjukkan fluktuasi yang dipengaruhi oleh berbagai faktor ekonomi dan dinamika pasar. Data rata-rata harga emas yang disediakan oleh Badan Pusat Statistik (BPS) merepresentasikan kondisi pasar emas domestik secara resmi dan sistematis. Namun, karakteristik data harga emas yang bersifat deret waktu, volatil, dan non-linear menjadikan proses prediksi harga sebagai permasalahan yang kompleks.

Metode statistik konvensional sering kali memiliki keterbatasan dalam menangani data dengan pola non-linear dan fluktuasi tinggi. Oleh karena itu, diperlukan pendekatan yang lebih adaptif dan fleksibel, yaitu metode *machine learning*. Dalam penelitian ini, algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression* dipilih karena keduanya memiliki kemampuan dalam memodelkan hubungan non-linear dan menangani data deret waktu dengan baik. SVR

efektif dalam membangun model regresi berbasis kernel dengan margin toleransi kesalahan tertentu, sedangkan *Random Forest* mampu menghasilkan prediksi yang stabil melalui mekanisme *ensemble learning*.

Salah satu tantangan utama dalam penerapan algoritma *machine learning* adalah pemilihan parameter model yang optimal. Parameter yang tidak tepat dapat menyebabkan model menghasilkan prediksi yang kurang akurat atau tidak stabil. Untuk mengatasi permasalahan tersebut, penelitian ini menerapkan Bayesian Optimization sebagai metode optimasi parameter pada algoritma SVR dan *Random Forest*. Bayesian Optimization dipilih karena mampu mencari kombinasi parameter terbaik secara efisien dalam ruang parameter yang besar dengan jumlah evaluasi yang lebih sedikit dibandingkan metode konvensional.

Berdasarkan pertimbangan tersebut, penelitian ini membangun alur pemodelan prediksi harga emas yang dimulai dari pengolahan data harga emas BPS, dilanjutkan dengan pra-pemrosesan data, pembangunan model prediksi menggunakan SVR dan *Random Forest* yang telah dioptimasi menggunakan Bayesian Optimization, serta evaluasi kinerja model menggunakan metrik evaluasi regresi. Hasil dari proses ini kemudian dibandingkan untuk menentukan algoritma yang memberikan performa prediksi terbaik pada data harga emas di Jakarta.



Gambar 2. 3 Bagan Kerangka Penelitian

*Halaman ini
sengaja dikosongkan*

BAB III

DESAIN DAN IMPLEMENTASI SISTEM

3.1 Metode Penelitian

Penelitian ini menggunakan dataset yang berfokus pada data rata-rata harga emas di pasaran Jakarta. Variabel penelitian dipilih berdasarkan tujuan penelitian, yaitu membangun model prediksi harga emas menggunakan pendekatan *machine learning* berbasis data deret waktu. Dalam penelitian ini, harga emas berperan sebagai variabel dependen (target) yang menjadi fokus utama prediksi. Data historis harga emas digunakan sebagai variabel input untuk mempelajari pola pergerakan harga dari waktu ke waktu.

Variabel yang digunakan dalam penelitian ini bersifat numerik kontinu dan disusun dalam bentuk deret waktu (*time series*). Pemilihan satu variabel utama dilakukan untuk menekankan kemampuan algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression* dalam menangkap pola non-linear dan volatilitas harga emas berdasarkan data historis tanpa bergantung pada variabel eksternal. Deskripsi variabel penelitian disajikan pada Tabel 3.1.

Tabel 3. 1 Deskripsi Variabel Penelitian

Variabel	Tipe Data	Penjelasan
Harga Emas	Numeric	Data rata-rata harga emas di pasaran Jakarta (Rupiah/gram) yang disusun sebagai data deret waktu

Data yang digunakan dalam penelitian ini dikumpulkan dalam rentang waktu tertentu sesuai dengan ketersediaan data dari sumber resmi, dengan frekuensi pengamatan mingguan atau bulanan. Rentang waktu yang relatif panjang memungkinkan model untuk mempelajari tren jangka panjang serta fluktuasi jangka pendek pada harga emas.


Sumber data dalam penelitian ini berasal dari Badan Pusat Statistik (BPS). Data harga emas diperoleh dari tabel statistik resmi BPS yang menyajikan perkembangan harga rata-rata emas di pasaran Jakarta. Data tersebut dapat diakses melalui laman resmi BPS pada tautan berikut:

<https://www.bps.go.id/id/statistics-table/2/MjQxMyMy/perkembangan-harga-rata-rata-emas-di-pasaran-jakarta.html>

Penggunaan data dari BPS didasarkan pada beberapa pertimbangan. Pertama, BPS merupakan lembaga pemerintah yang memiliki kewenangan resmi dalam penyediaan data statistik nasional, sehingga data yang disajikan memiliki tingkat keandalan dan validitas yang tinggi. Kedua, data harga emas dari BPS dikumpulkan dan dipublikasikan secara sistematis, sehingga konsisten untuk digunakan dalam analisis deret waktu. Ketiga, data tersebut merepresentasikan kondisi pasar emas domestik, khususnya di Jakarta, yang menjadi fokus wilayah penelitian ini.

Secara umum, data harga emas yang digunakan menunjukkan karakteristik fluktuatif dengan kecenderungan tren tertentu dalam jangka panjang. Selain itu, pada beberapa periode tertentu terdapat nilai harga yang relatif stagnan atau perubahan yang tidak signifikan antar periode. Kondisi tersebut mencerminkan sifat data deret waktu yang volatil dan non-linear, sehingga memerlukan tahapan pra-pemrosesan sebelum dilakukan pemodelan. Tahapan tersebut meliputi pembersihan data, penyesuaian format waktu, serta normalisasi data untuk memastikan kesesuaian dengan algoritma machine learning yang digunakan.

Berdasarkan variabel penelitian dan sumber data yang telah dijelaskan, dataset harga emas dari BPS dinilai sesuai untuk digunakan dalam penelitian prediksi harga emas. Data tersebut diharapkan mampu mendukung proses pembangunan dan evaluasi model SVR dan *Random Forest* secara objektif dalam konteks prediksi harga emas di Jakarta.



Gambar 3. 1 Prediksi harga emas dengan pembelajaran mesin

Gambar metode penelitian di atas menggambarkan alur proses prediksi harga emas di Jakarta yang dimulai dari data historis hingga dihasilkan nilai prediksi menggunakan dua algoritma pembelajaran mesin, yaitu *Support Vector Regression* (SVR) dan *Random Forest Regression*. Alur ini disusun untuk memastikan setiap tahapan pemodelan dilakukan secara sistematis dan terstruktur.

Tahap awal proses dimulai dari data historis harga emas yang diperoleh dari Badan Pusat Statistik (BPS). Data ini berperan sebagai variabel input utama yang merepresentasikan pergerakan harga emas dalam bentuk deret waktu. Data historis tersebut kemudian memasuki tahap pra-pemrosesan, yang bertujuan untuk meningkatkan kualitas data sebelum digunakan dalam proses pemodelan. Tahapan pra-pemrosesan meliputi pembersihan data dari nilai yang hilang atau tidak konsisten, penyesuaian format waktu, serta normalisasi data menggunakan metode Min-Max Scaler agar skala data sesuai dengan kebutuhan algoritma pembelajaran mesin.

Setelah data melalui tahap pra-pemrosesan, dilakukan ekstraksi fitur. Pada tahap ini, fitur-fitur yang relevan diturunkan dari data historis harga emas, seperti nilai harga pada periode sebelumnya (*lag features*), rata-rata bergerak, dan indikator waktu. Ekstraksi fitur bertujuan untuk membantu model dalam mengenali pola pergerakan harga emas secara lebih efektif.


Data yang telah diproses dan diekstraksi fiturnya selanjutnya digunakan dalam proses pemodelan prediksi harga emas. Pada tahap ini, dua algoritma yang berbeda diterapkan, yaitu *Support Vector Regression* (SVR) dan *Random Forest Regression*.

SVR digunakan karena kemampuannya dalam memodelkan hubungan non-linear menggunakan fungsi kernel, sedangkan *Random Forest* digunakan karena keunggulannya dalam menghasilkan prediksi yang stabil melalui mekanisme *ensemble learning*. Kedua algoritma tersebut digunakan secara paralel untuk memungkinkan perbandingan kinerja model secara objektif.

Hasil dari masing-masing model kemudian digunakan untuk menghasilkan prediksi harga emas pada periode selanjutnya. Prediksi yang dihasilkan oleh SVR dan *Random Forest* selanjutnya dievaluasi menggunakan metrik evaluasi regresi, seperti *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE), guna menilai tingkat akurasi dan keandalan model. Melalui proses ini, diperoleh model prediksi harga emas yang memiliki kinerja terbaik berdasarkan hasil evaluasi yang telah dilakukan.

3.2 Langkah Analisis

Penelitian ini mengikuti serangkaian langkah analisis yang sistematis untuk membangun model prediksi harga emas di Jakarta yang akurat dan sesuai dengan tujuan penelitian. Langkah-langkah analisis disusun secara berurutan mulai dari pengumpulan data, pra-pemrosesan, pembentukan model prediksi, hingga evaluasi kinerja model. Alur langkah analisis penelitian ini ditunjukkan pada Gambar 3.2



Gambar 3. 2 Langkah Analisis Penelitian

Gambar 3.2 menunjukkan tahapan analisis yang dilakukan dalam penelitian ini. Proses dimulai dari tahap Data Collection, yaitu pengumpulan data historis harga emas di Jakarta yang diperoleh dari Badan Pusat Statistik (BPS). Data yang telah dikumpulkan kemudian melalui tahap Data Pre-processing untuk memastikan kualitas data, meliputi pembersihan data, penyesuaian format, dan penanganan nilai yang hilang.

Selanjutnya, dilakukan tahap *Feature engineering* untuk membentuk fitur-fitur yang relevan dari data deret waktu. Data kemudian dibagi menjadi data latih dan data uji serta dilakukan Scaling menggunakan Min–Max Scaler agar skala data seragam dan sesuai dengan kebutuhan algoritma pembelajaran mesin.

Tahap berikutnya adalah Data Modelling, di mana model prediksi dibangun menggunakan algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression*. Untuk meningkatkan performa model, dilakukan Hyperparameter Tuning menggunakan Bayesian Optimization. Model yang telah dioptimasi kemudian melalui proses Training dan Testing menggunakan data yang telah dibagi sebelumnya.

Hasil prediksi dari masing-masing model dievaluasi pada tahap Model Evaluation menggunakan metrik MAE, RMSE, dan MAPE. Berdasarkan hasil evaluasi tersebut, dipilih model dengan performa terbaik yang selanjutnya digunakan untuk menghasilkan prediksi harga emas dan visualisasi hasil.

Beberapa tahapan utama yang dilakukan dalam penelitian ini meliputi pengumpulan data harga emas, pengolahan dan analisis data deret waktu, penerapan algoritma *machine learning*, serta evaluasi dan perbandingan kinerja model prediksi. Seluruh tahapan tersebut dirancang secara sistematis untuk memastikan bahwa model prediksi yang dibangun mampu menangkap pola pergerakan harga emas secara akurat dan dapat dipertanggungjawabkan secara ilmiah. Adapun tahapan analisis yang dilakukan dalam penelitian ini dijelaskan sebagai berikut.

1 *Data Collection*

Tahap awal dalam penelitian ini adalah Data Collection, yaitu proses pengumpulan data historis harga emas yang akan digunakan sebagai dasar dalam pemodelan prediksi. Data yang digunakan berupa data rata-rata harga emas di pasaran Jakarta yang diperoleh dari Badan Pusat Statistik (BPS) melalui laman resmi BPS. Pemilihan data dari BPS didasarkan pada kredibilitas lembaga serta konsistensi metodologi

pengumpulan data yang digunakan, sehingga data yang dihasilkan memiliki tingkat keandalan yang tinggi.

Data harga emas dikumpulkan sesuai dengan periode penelitian yang telah ditentukan dan disusun berdasarkan urutan waktu tertentu (misalnya mingguan atau bulanan). Penyusunan data secara kronologis ini membentuk data deret waktu (*time series*), yang memungkinkan analisis pola pergerakan harga dari waktu ke waktu. Data deret waktu memiliki karakteristik ketergantungan temporal, di mana nilai pada periode tertentu dipengaruhi oleh nilai pada periode sebelumnya. Oleh karena itu, penggunaan data historis harga emas menjadi sangat relevan dalam proses prediksi harga di masa mendatang.

Selain itu, tahap pengumpulan data juga mencakup proses verifikasi awal terhadap kelengkapan data, seperti pengecekan periode yang hilang, format tanggal, serta konsistensi satuan harga. Langkah ini bertujuan untuk memastikan bahwa data yang digunakan telah sesuai dengan kebutuhan analisis dan siap untuk diproses pada tahap selanjutnya.

Sebagai ilustrasi, struktur data harga emas yang digunakan dalam penelitian ini dapat digambarkan secara konseptual pada Tabel 3.2.

Tabel 3. 2 Data Emas BPS

Tahun	Bulan	Minggu	Harga Emas (Rp/gram)	Tanggal
2013	Januari	1	1.269.951	1-Jan-13
2013	Januari	2	1.267.233	8-Jan-13
2013	Januari	3	1.279.218	15-Jan-13
...	...	...	...	...

Tabel tersebut menunjukkan bahwa data harga emas tersusun berdasarkan dimensi waktu yang jelas dan berurutan. Struktur data seperti ini sangat sesuai untuk analisis deret waktu dan penerapan algoritma *machine learning* berbasis regresi, seperti Support Vector Regression (SVR) dan Random Forest Regression.

Dengan demikian, tahap Data Collection berperan penting dalam menyediakan data yang valid dan representatif sebagai fondasi utama dalam seluruh proses analisis dan pemodelan prediksi harga emas pada penelitian ini.

2 Data Pre-processing

Tahap Data Pre-processing merupakan tahapan penting yang bertujuan untuk meningkatkan kualitas data sebelum digunakan dalam proses pemodelan prediksi. Pada tahap ini, data historis harga emas yang telah dikumpulkan dari Badan Pusat Statistik (BPS) dipersiapkan agar sesuai dengan kebutuhan analisis deret waktu dan algoritma *machine learning* yang digunakan dalam penelitian ini.

Proses pra-pemrosesan diawali dengan pengecekan dan penyesuaian format data, khususnya pada kolom waktu. Kolom tanggal dikonversi ke dalam format *datetime* agar dapat diproses secara kronologis dan memungkinkan penerapan analisis deret waktu secara tepat. Penyesuaian format ini juga memudahkan proses pengurutan data berdasarkan waktu serta pembentukan fitur temporal pada tahap selanjutnya.

Selanjutnya dilakukan identifikasi terhadap kualitas data, meliputi pemeriksaan nilai yang hilang (*missing value*), data duplikat, serta ketidakkonsistenan pencatatan harga. Nilai yang hilang dapat muncul akibat keterbatasan pencatatan pada periode tertentu atau perbedaan format publikasi data. Untuk menjaga kontinuitas data deret waktu, nilai yang hilang ditangani menggunakan metode imputasi yang sesuai, seperti *forward fill*, yaitu dengan mengisi nilai yang hilang menggunakan nilai pada periode sebelumnya. Pendekatan ini dipilih karena mempertahankan pola historis dan urutan waktu data tanpa memperkenalkan distorsi yang signifikan.

Selain itu, data juga diperiksa untuk mendeteksi anomali atau pencatatan yang tidak wajar, seperti lonjakan harga yang tidak konsisten dengan pola umum. Apabila ditemukan anomali yang disebabkan oleh kesalahan pencatatan, dilakukan koreksi atau penyesuaian berdasarkan referensi data yang valid. Proses ini bertujuan untuk meminimalkan pengaruh noise yang dapat menurunkan kinerja model prediksi.

Sebagai ilustrasi, proses pembersihan data pada tahap pra-pemrosesan dapat digambarkan secara konseptual pada Tabel 3.3.

Tabel 3. 3 Contoh Penanganan Missing Value pada Data Harga Emas

Tanggal	Harga Emas (Sebelum)	Metode Imputasi	Harga Emas (Sesudah)
15-Mar-13	1.402.637	–	1.402.637
22-Mar-13	–	Forward Fill	1.402.637
29-Mar-13	1.431.687	–	1.431.687

Tabel tersebut menunjukkan bahwa nilai harga emas yang hilang pada suatu periode diisi menggunakan nilai harga pada periode sebelumnya, sehingga urutan data tetap terjaga dan tidak terputus.

Tahap Data *Pre-processing* ini sangat krusial karena kualitas data yang baik akan berpengaruh langsung terhadap performa model prediksi. Data yang bersih, konsisten, dan terstruktur dengan baik akan membantu algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression* dalam mempelajari pola pergerakan harga emas secara lebih akurat. Dengan demikian, tahap pra-pemrosesan menjadi fondasi utama dalam keseluruhan proses analisis dan pemodelan pada penelitian ini.

3 *Feature Engineering*

Tahap *Feature engineering* bertujuan untuk membentuk dan mengekstraksi fitur-fitur yang relevan dari data historis harga emas guna meningkatkan kemampuan model dalam mengenali pola pergerakan harga. Pada data deret waktu (*time series*), nilai pada suatu periode umumnya dipengaruhi oleh nilai pada periode-periode sebelumnya. Oleh karena itu, proses *feature engineering* difokuskan pada pembentukan fitur yang mampu merepresentasikan ketergantungan temporal dan dinamika perubahan harga emas dari waktu ke waktu.

Salah satu teknik utama yang digunakan pada tahap ini adalah pembentukan lag features. *Lag feature* merupakan nilai harga emas pada periode sebelumnya yang digunakan sebagai variabel input untuk memprediksi harga pada periode saat ini atau periode mendatang. Dengan memasukkan nilai harga pada beberapa periode sebelumnya, model diharapkan mampu mempelajari hubungan historis antar waktu serta pola pergerakan harga yang bersifat berurutan. Dalam penelitian ini, beberapa lag digunakan, seperti lag-1, lag-2, dan lag-3, yang merepresentasikan harga emas satu, dua, dan tiga periode sebelumnya.

Selain lag features, dilakukan pula pembentukan fitur moving average (rata-rata bergerak). Moving average digunakan untuk menghaluskan fluktuasi jangka pendek dan menonjolkan tren pergerakan harga dalam jangka waktu tertentu. Fitur ini dihitung sebagai rata-rata harga emas pada sejumlah periode sebelumnya, misalnya moving average 3 periode (MA-3) atau moving average 5 periode (MA-5). Penggunaan moving average membantu model dalam menangkap tren umum harga emas dan mengurangi pengaruh noise yang terdapat pada data.

Secara konseptual, contoh pembentukan lag features dan moving average dapat dilihat pada Tabel 3.4.

Tabel 3. 4 Contoh *Feature engineering* pada Data Harga Emas

Tanggal	Harga Emas (Rp)	Lag-1	Lag-2	Lag-3	MA-3
1-Jan-13	1.269.951	–	–	–	–
8-Jan-13	1.267.233	1.269.951	–	–	–
15-Jan-13	1.279.218	1.267.233	1.269.951	–	1.272.134
22-Jan-13	1.274.211	1.279.218	1.267.233	1.269.951	1.273.554

Tabel tersebut menunjukkan bahwa nilai lag diisi berdasarkan harga emas pada periode sebelumnya, sedangkan nilai moving average dihitung dari rata-rata harga emas pada beberapa periode terakhir. Pada periode awal, nilai lag dan moving average belum tersedia secara lengkap sehingga menghasilkan nilai kosong yang kemudian ditangani pada tahap selanjutnya.

Proses *feature engineering* dilakukan dengan tetap memperhatikan urutan waktu data untuk menghindari terjadinya *data leakage*, yaitu penggunaan informasi masa depan dalam proses pelatihan model. Oleh karena itu, seluruh fitur dibentuk hanya menggunakan data dari periode sebelumnya.

Fitur-fitur hasil *feature engineering* ini selanjutnya digunakan sebagai variabel input pada tahap pemodelan menggunakan algoritma Support Vector Regression (SVR) dan Random Forest Regression. Dengan adanya fitur lag dan moving average, model diharapkan mampu menangkap pola non-linear, tren jangka panjang, serta fluktuasi jangka pendek pada harga emas secara lebih efektif.

4 *Data Splitting & Scaling (Min–Max Scaler)*

Tahap Data Splitting & Scaling bertujuan untuk mempersiapkan data agar dapat digunakan secara optimal dalam proses pelatihan dan pengujian model

prediksi. Pada penelitian ini, data yang telah melalui tahap pra-pemrosesan dan feature engineering selanjutnya dibagi menjadi dua bagian utama, yaitu data latih (training data) dan data uji (testing data). Pembagian data dilakukan dengan mempertimbangkan karakteristik data deret waktu, di mana urutan waktu harus tetap dipertahankan.

Pembagian data dilakukan berdasarkan urutan kronologis (*time-based splitting*), bukan secara acak. Pendekatan ini dipilih untuk mencegah terjadinya *data leakage*, yaitu kondisi di mana informasi dari masa depan secara tidak sengaja digunakan dalam proses pelatihan model. Data pada periode awal digunakan sebagai data latih, sedangkan data pada periode selanjutnya digunakan sebagai data uji. Rasio pembagian data disesuaikan dengan kebutuhan penelitian, misalnya 80% data latih dan 20% data uji, sehingga model memiliki cukup data untuk mempelajari pola historis sekaligus diuji pada data yang belum pernah dilihat sebelumnya.

Setelah data dibagi, dilakukan proses scaling atau normalisasi data menggunakan metode Min–Max Scaler. Normalisasi bertujuan untuk mengubah rentang nilai data ke dalam skala yang seragam, umumnya pada interval [0, 1]. Proses ini sangat penting terutama untuk algoritma Support Vector Regression (SVR), yang sensitif terhadap perbedaan skala antar fitur. Dengan melakukan normalisasi, setiap fitur memiliki kontribusi yang seimbang dalam proses pembelajaran model.

Secara matematis, transformasi Min–Max Scaler dirumuskan sebagai berikut:

$$x = \frac{x - x_{min}}{x_{max} - x_{min}}$$

dengan keterangan:

x : nilai data asli,

x : nilai data hasil normalisasi,

x_{min} : nilai minimum dari fitur,

x_{max} : nilai maksimum dari fitur.

Proses scaling dilakukan hanya menggunakan data latih untuk menghitung nilai minimum dan maksimum. Parameter tersebut kemudian diterapkan pada data uji. Pendekatan ini penting untuk menjaga integritas evaluasi model dan mencegah kebocoran informasi dari data uji ke data latih.

Sebagai ilustrasi, contoh proses normalisasi data harga emas menggunakan Min–Max Scaler ditunjukkan pada Tabel 3.5.

Tabel 3. 5 Contoh Proses Normalisasi Data Harga Emas

Harga Emas (Rp)	Nilai Minimum	Nilai Maksimum	Harga Emas (Ternormalisasi)
1.267.233	1.267.233	1.995.432	0
1.402.637	1.267.233	1.995.432	0.19
1.686.388	1.267.233	1.995.432	0.58
1.995.432	1.267.233	1.995.432	1

Tabel tersebut menunjukkan bahwa nilai harga emas asli yang memiliki skala besar diubah menjadi nilai dalam rentang 0 hingga 1, sehingga lebih mudah diproses oleh algoritma *machine learning*.

Melalui tahap Data Splitting & Scaling ini, data yang digunakan dalam penelitian telah siap untuk digunakan pada tahap pemodelan. Pembagian data yang tepat serta normalisasi yang konsisten diharapkan dapat meningkatkan kemampuan model dalam mempelajari pola pergerakan harga emas dan menghasilkan prediksi yang lebih akurat serta stabil.

Pada penelitian ini, pembagian data dilakukan dengan rasio 80:20, di mana 80% data digunakan sebagai data latih (training data) dan 20% data digunakan sebagai data uji (testing data). Pemilihan rasio 80:20 dilakukan karena dianggap mampu memberikan keseimbangan antara jumlah data yang cukup untuk melatih model dan data yang memadai untuk menguji kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Pembagian data dilakukan berdasarkan urutan waktu (time-based splitting) untuk mempertahankan karakteristik data deret waktu. Data pada periode awal digunakan sebagai data latih, sedangkan data pada periode selanjutnya digunakan sebagai data uji. Pendekatan ini mencerminkan kondisi prediksi yang realistis, di mana model dilatih menggunakan data historis dan diuji untuk memprediksi harga pada periode mendatang.

Sebagai ilustrasi, jika dataset terdiri dari N observasi, maka sebanyak $0,8 N$ observasi pertama digunakan sebagai data latih dan sisanya sebanyak $0,2 N$ observasi terakhir digunakan sebagai data uji. Pembagian ini memastikan bahwa model tidak memanfaatkan informasi masa depan dalam proses pelatihan,

sehingga hasil evaluasi model dapat mencerminkan performa prediksi yang objektif dan dapat dipercaya.

Dengan penerapan pembagian data 80:20 yang berbasis urutan waktu ini, model Support Vector Regression (SVR) dan Random Forest Regression diharapkan mampu mempelajari pola pergerakan harga emas secara optimal serta menunjukkan kinerja prediksi yang stabil pada data uji.

5 Data Modelling

Tahap Data Modelling merupakan tahap inti dalam penelitian ini, di mana model prediksi harga emas dibangun menggunakan algoritma *machine learning* yang telah dipilih. Pada penelitian ini digunakan dua algoritma regresi, yaitu *Support Vector Regression* (SVR) dan *Random Forest Regression*. Kedua algoritma tersebut diterapkan secara terpisah menggunakan data latih yang sama agar perbandingan kinerja model dapat dilakukan secara objektif.

a. Data Modelling menggunakan *Support Vector Regression* (SVR)

Support Vector Regression (SVR) merupakan pengembangan dari *Support Vector Machine* (SVM) yang digunakan untuk permasalahan regresi. SVR bekerja dengan membangun sebuah fungsi regresi yang berusaha meminimalkan kesalahan prediksi dengan tetap mempertahankan margin toleransi kesalahan tertentu yang disebut sebagai *ϵ -insensitive tube*. Pendekatan ini memungkinkan SVR untuk menangani data yang bersifat non-linear dengan baik melalui penggunaan fungsi kernel.

Pada penelitian ini, model SVR dibangun menggunakan data latih hasil tahap sebelumnya yang telah dinormalisasi menggunakan Min-Max Scaler. Normalisasi diperlukan karena SVR sensitif terhadap perbedaan skala data. Fitur-fitur hasil *feature engineering*, seperti lag harga dan moving average, digunakan sebagai variabel input, sedangkan harga emas pada periode selanjutnya digunakan sebagai variabel target.

Pemodelan SVR dilakukan dengan menentukan fungsi kernel yang sesuai, seperti kernel Radial Basis Function (RBF), yang umum digunakan untuk menangkap hubungan non-linear pada data deret waktu. Model SVR kemudian dilatih menggunakan data latih untuk mempelajari pola hubungan antara fitur input dan harga emas. Parameter-parameter penting

pada SVR, seperti parameter penalti dan toleransi kesalahan, belum ditetapkan secara tetap pada tahap ini dan akan dioptimalkan pada tahap selanjutnya menggunakan *Bayesian Optimization*.

b. Data Modelling menggunakan *Random Forest Regression*

Random Forest Regression merupakan metode *ensemble learning* yang membangun sejumlah pohon keputusan (*decision tree*) dan menggabungkan hasil prediksi dari seluruh pohon tersebut untuk menghasilkan prediksi akhir. Pendekatan ini bertujuan untuk meningkatkan stabilitas dan akurasi model serta mengurangi risiko *overfitting* yang sering terjadi pada model pohon keputusan tunggal.

Pada penelitian ini, model Random Forest Regression dibangun menggunakan data latih yang sama dengan model SVR agar perbandingan kinerja kedua algoritma dapat dilakukan secara adil. Berbeda dengan SVR, Random Forest relatif tidak sensitif terhadap skala data. Namun demikian, proses normalisasi tetap diterapkan untuk menjaga konsistensi perlakuan data pada seluruh model yang digunakan.

Model Random Forest dilatih dengan membangun sejumlah pohon keputusan berdasarkan sampel data yang diambil secara acak (*bootstrap sampling*). Pada setiap node pohon, hanya sebagian fitur yang dipilih secara acak untuk menentukan pemisahan terbaik. Proses ini memungkinkan model untuk menangkap interaksi kompleks antar fitur serta menghasilkan prediksi yang lebih robust terhadap noise dan fluktuasi data harga emas.

Parameter penting pada Random Forest, seperti jumlah pohon (*number of trees*) dan kedalaman pohon, pada tahap ini masih menggunakan nilai awal. Nilai parameter tersebut selanjutnya akan dioptimalkan pada tahap hyperparameter tuning menggunakan Bayesian Optimization untuk memperoleh performa prediksi yang optimal.

6 *Model Evaluation*

Tahap Model Evaluation dilakukan untuk mengukur kinerja dan tingkat akurasi model dalam memprediksi harga emas. Evaluasi ini bertujuan untuk mengetahui seberapa baik model Support Vector Regression (SVR) dan Random Forest Regression dalam mempelajari pola historis data dan

menghasilkan prediksi yang mendekati nilai aktual. Pengujian dilakukan menggunakan data uji (testing data) yang sebelumnya telah dipisahkan dari data latih agar hasil evaluasi mencerminkan kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Pada penelitian ini, evaluasi kinerja model dilakukan menggunakan beberapa metrik evaluasi regresi, yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE). Ketiga metrik tersebut digunakan secara bersamaan untuk memberikan gambaran yang komprehensif mengenai kesalahan prediksi model, baik dalam satuan absolut, kuadrat kesalahan, maupun dalam bentuk persentase. Penggunaan lebih dari satu metrik evaluasi penting untuk menghindari bias penilaian terhadap satu aspek kinerja model saja.

Hasil evaluasi yang diperoleh dari masing-masing metrik kemudian digunakan sebagai dasar untuk menilai tingkat akurasi prediksi yang dihasilkan oleh model SVR dan Random Forest. Pendekatan ini sejalan dengan penelitian-penelitian sebelumnya yang menekankan pentingnya evaluasi model secara menyeluruh dalam pengembangan sistem prediktif berbasis *machine learning*. Selanjutnya, dilakukan perbandingan performa antara model SVR dan Random Forest berdasarkan nilai MAE, RMSE, dan MAPE untuk menentukan algoritma yang memberikan kinerja paling optimal dalam konteks prediksi harga emas.

Selain evaluasi numerik, pada tahap ini juga dilakukan visualisasi perbandingan antara nilai aktual dan nilai prediksi. Visualisasi tersebut bertujuan untuk memberikan gambaran secara intuitif mengenai kedekatan hasil prediksi model terhadap data aktual, serta untuk mengamati pola kesalahan prediksi yang terjadi pada masing-masing model.

7 *Prediksi Harga Emas*

Setelah diperoleh model dengan kinerja terbaik berdasarkan hasil evaluasi, tahap selanjutnya adalah Prediksi Harga Emas. Pada tahap ini, model terbaik digunakan untuk memprediksi harga emas pada periode waktu mendatang. Proses prediksi dilakukan secara berurutan dan sistematis dengan memanfaatkan data historis yang telah dipelajari oleh model.

Prediksi dilakukan untuk beberapa periode ke depan dengan pendekatan deret waktu, di mana hasil prediksi pada suatu periode dapat digunakan sebagai input untuk memprediksi periode berikutnya. Pendekatan ini memungkinkan model untuk menghasilkan estimasi pergerakan harga emas secara berkelanjutan sesuai dengan pola historis yang telah dipelajari. Proses prediksi ini mencerminkan kondisi prediksi nyata yang dihadapi dalam praktik, khususnya dalam pengambilan keputusan investasi.

Hasil prediksi harga emas selanjutnya disajikan dalam bentuk tabel dan grafik untuk memudahkan proses analisis dan interpretasi. Penyajian dalam bentuk visual memungkinkan perbandingan antara pola historis dan hasil prediksi dilakukan secara lebih informatif. Melalui analisis ini, diharapkan model mampu menangkap pola pergerakan harga emas secara lebih akurat dan memberikan gambaran yang jelas mengenai tren harga emas di masa mendatang.

3.3 Desain Sistem

Desain sistem aplikasi prediksi harga emas yang dikembangkan dalam penelitian ini menggunakan framework Streamlit sebagai antarmuka pengguna. Sistem ini dirancang untuk memudahkan pengguna dalam melakukan analisis data harga emas serta memprediksi harga emas menggunakan algoritma *Support Vector Regression* (SVR) dan *Random Forest Regression*. Penggunaan Streamlit memungkinkan implementasi sistem analitik berbasis *machine learning* secara interaktif, ringan, dan mudah diakses melalui web browser tanpa memerlukan instalasi perangkat lunak tambahan.

3.3.1 Arsitektur Sistem

Arsitektur sistem dalam penelitian ini terdiri dari beberapa komponen utama yang saling terintegrasi untuk mendukung proses prediksi harga emas secara menyeluruh. Sistem dibangun dalam satu lingkungan Python, di mana Streamlit berperan sebagai lapisan antarmuka pengguna (*presentation layer*), sedangkan proses analisis data dan pemodelan *machine learning* dijalankan pada lapisan logika aplikasi (*application layer*).

Secara umum, sistem mencakup fitur pengolahan data, pemodelan prediksi, evaluasi model, serta visualisasi hasil. Hasil analisis dan prediksi disajikan dalam bentuk dashboard interaktif yang mendukung proses analisis dan


pengambilan keputusan berbasis data. Selain itu, sistem juga menyediakan fitur evaluasi prediksi untuk membandingkan nilai aktual dan nilai hasil prediksi secara kuantitatif dan visual.

a) Struktur Aplikasi

Aplikasi Streamlit yang dikembangkan dalam penelitian ini terdiri dari beberapa modul utama, yaitu:

1. Dashboard / Home

Berfungsi sebagai halaman utama yang menampilkan ringkasan data harga emas dan visualisasi data historis secara umum.




Gambar 3.3 Mock-up Home / Dashboard

Gambar 3.3 menjelaskan tampilan halaman Dashboard sebagai halaman utama pada sistem prediksi harga emas berbasis Streamlit. Halaman ini menampilkan ringkasan informasi data harga emas yang digunakan dalam penelitian, termasuk periode pengamatan dan jumlah data. Selain itu, disajikan grafik deret waktu harga emas historis.

2. Historical Data

Modul ini digunakan untuk menampilkan dan menganalisis data historis harga emas dalam bentuk tabel dan grafik deret waktu, sehingga pengguna dapat memahami pola dan tren harga emas.




Gambar 3.4 Mock Up Hostorical Data

Gambar 3.4 menjelaskan tampilan modul Historical Data yang digunakan untuk menampilkan data historis harga emas secara rinci. Data disajikan dalam bentuk tabel untuk memudahkan pengamatan nilai harga pada setiap periode, serta grafik deret waktu untuk membantu pengguna memahami pola pergerakan, tren, dan volatilitas harga emas. Modul ini berfungsi sebagai dasar analisis sebelum dilakukan proses pemodelan dan prediksi.

3. Prediksi Harga Emas

Modul inti yang digunakan untuk melakukan proses pra-pemrosesan data, pelatihan model SVR dan Random Forest, serta menghasilkan prediksi harga emas untuk periode mendatang.




Gambar 3.5 MockUp Prediksi Harga Emas

Gambar 3.5 menjelaskan tampilan modul Prediksi Harga Emas, yang merupakan modul inti dalam sistem. Pada halaman ini, pengguna dapat menjalankan proses prediksi harga emas untuk periode mendatang. Sistem secara otomatis melakukan pra-pemrosesan data, pembentukan fitur, pelatihan model Support Vector Regression (SVR) dan Random Forest Regression, serta optimasi parameter menggunakan Bayesian Optimization. Hasil prediksi ditampilkan dalam bentuk tabel dan grafik untuk memudahkan analisis dan interpretasi.

4. Evaluasi Model

Modul ini berfungsi untuk menampilkan hasil evaluasi kinerja model menggunakan metrik MAE, RMSE, dan MAPE, serta membandingkan performa antar model.




Gambar 3. 6 Mock Up Evaluasi Model

Gambar 3.6 menjelaskan tampilan modul Evaluasi Model yang digunakan untuk menilai kinerja model prediksi harga emas. Pada halaman ini ditampilkan nilai metrik evaluasi Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE) untuk masing-masing algoritma. Selain itu, disajikan grafik perbandingan antara nilai aktual dan hasil prediksi guna memberikan gambaran visual mengenai tingkat akurasi dan kesalahan prediksi model. About Menyediakan informasi singkat mengenai sistem, metode yang digunakan, dan tujuan pengembangan aplikasi.

5. About

Menyediakan informasi singkat mengenai sistem, metode yang digunakan, dan tujuan pengembangan aplikasi.



Gambar 3. 7 Mock Up About

Gambar 3.7 menjelaskan tampilan modul About yang berisi informasi singkat mengenai sistem prediksi harga emas. Halaman ini menjelaskan tujuan pengembangan sistem, metode pembelajaran mesin yang digunakan, serta konteks penelitian secara umum. Modul About

berfungsi sebagai dokumentasi singkat agar pengguna memahami latar belakang dan ruang lingkup sistem yang dikembangkan.


3.3.2 Alur Kerja Sistem

Alur kerja sistem prediksi harga emas yang dikembangkan dalam penelitian ini adalah sebagai berikut:

1. Pengguna memuat data historis harga emas dari BPS.
2. Sistem melakukan pra-pemrosesan dan *feature engineering* secara otomatis.
3. Data dibagi menjadi data latih dan data uji sesuai rasio yang ditentukan.
4. Sistem melatih model SVR dan Random Forest dengan parameter optimal.
5. Sistem menampilkan hasil evaluasi kinerja model.
6. Pengguna menentukan periode prediksi yang diinginkan.
7. Sistem menghasilkan dan menampilkan hasil prediksi dalam bentuk tabel dan grafik.

Berikut alur kerja sistem dalam bentuk Flowchart

Flowchart Sistem Prediksi Harga Emas Berbasis Streamlit



Gambar 3. 8 Flowchart Sistem Prediksi Emas

Gambar 3.8 menunjukkan flowchart sistem prediksi harga emas berbasis Streamlit yang dikembangkan dalam penelitian ini. Flowchart ini menggambarkan alur kerja sistem secara menyeluruh, dimulai dari interaksi pengguna hingga dihasilkan output prediksi harga emas.

Proses diawali ketika pengguna membuka sistem dan memuat data historis harga emas yang bersumber dari Badan Pusat Statistik (BPS). Sistem kemudian melakukan validasi data untuk memastikan bahwa data yang dimasukkan sesuai dengan format dan kebutuhan analisis. Apabila data tidak valid, sistem akan menampilkan pesan kesalahan dan proses tidak dilanjutkan.

Jika data valid, sistem melanjutkan ke tahap data pre-processing, yang meliputi pembersihan data dan penanganan nilai yang hilang. Selanjutnya dilakukan feature engineering dengan membentuk fitur lag dan moving average untuk merepresentasikan ketergantungan waktu pada data harga emas.

Data yang telah diproses kemudian dibagi menjadi data latih dan data uji dengan rasio 80:20 serta dinormalisasi menggunakan metode Min–Max Scaler. Tahap berikutnya adalah pembangunan model prediksi menggunakan algoritma Support Vector Regression (SVR) dan Random Forest Regression, yang dioptimasi menggunakan Bayesian Optimization.

Setelah model dilatih dan diuji, sistem melakukan evaluasi model menggunakan metrik MAE, RMSE, dan MAPE. Berdasarkan hasil evaluasi tersebut, model dengan performa terbaik dipilih dan digunakan untuk melakukan prediksi harga emas pada periode mendatang. Hasil prediksi kemudian ditampilkan dalam bentuk tabel dan grafik sebagai output sistem.

Halaman ini sengaja dikosongkan

DAFTAR PUSTAKA

- [1] D. Nudia, “EMAS SEBAGAI INSTRUMEN INVESTASI JANGKA PANJANG,” *Shar-E : Jurnal Kajian Ekonomi Hukum Syariah*, vol. 8, no. 1, 2022, doi: 10.37567/shar-e.v8i1.1297.
- [2] Anita, “Analisis Komparasi Investasi Logam Mulia Emas,” *Jurnal Bisnis dan Manajemen*, vol. 5, no. 2, 2015.
- [3] R. Rahim, “Pengaruh Nilai Tukar Rupiah Dan Harga Emas Terhadap Indeks Harga Saham Gabungan (IHSG) Di Bursa Efek Indonesia (BEI) Saat Pandemi Covid-19,” *Jurnal Ilmiah Mahasiswa FEB, Universitas Brawijaya*, vol. 10, no. 1, 2021.
- [4] J. P. H. T. Jiawei Han, “Data Mining Concepts and Techniques,” 2022.
- [5] D. Mahayana, “A Data-Driven Approach to Spacecraft Attitude Control Using Support Vector Regression (SVR),” *IEEE Access*, vol. 12, 2024, doi: 10.1109/ACCESS.2024.3506983.
- [6] S. Annas, Z. Rais, A. Aswi, Indrayasaro, and Nurfajriani, “Implementation of Support Vector Regression (SVR) Analysis in Predicting Gold Prices in Indonesia,” 2023, pp. 97–107. doi: 10.2991/978-94-6463-332-0_12.
- [7] T. Gopi Krishna *et al.*, “Gold price prediction using random forest regression,” *Edu - Tech Enterprise*, vol. 3, p. 23, Apr. 2025, doi: 10.71459/edutech202523.
- [8] Cd. Rami Reddy and R. Khan, “Gold Price Prediction Using Machine Learning Algorithms,” *Internaaonal Journal of Sciennfic Research and Engineering Development*, vol. 8, [Online]. Available: www.ijsred.com
- [9]. Swarna S, “Machine Learning Based Heart Disease Prediction Using Random Forest,” *INTERANTIONAL JOURNAL OF SCIENTIFIC RESEARCH IN ENGINEERING AND MANAGEMENT*, vol. 08, no. 04, 2024, doi: 10.55041/ijsrem31320.
- [10] G. Angayarkanni and S. Hemalatha, “Evaluating the Performance of Supervised Machine Learning Algorithms for Predicting Multiple Diseases: A Comparative Study,” in *2023 9th International Conference on Advanced Computing and Communication Systems, ICACCS 2023*, 2023. doi: 10.1109/ICACCS57279.2023.10113100.

- [11] S. Al Bukhari and S. Pervaiz, "Machine Learning for Cutting Process Optimization: Comparison of Decision Tree and Bayesian Optimization-Random Forest Regression Models," in *Advances in Science and Engineering Technology International Conferences, ASET*, 2024. doi: 10.1109/ASET60340.2024.10708708.
- [12] J. Ganapa, S. Choudari, and M. rao K, "Gold Price Prediction Using Random Forest Regression," *Educational Administration Theory and Practices*, Jan. 2024, doi: 10.53555/kuey.v30i1.5928.
- [13] B. Xie, "Gold Price Forecast: A Summary of the Integration of Economic Factors and Calculation Methods," *INSTICC*, Sep. 2025, pp. 360–365. doi: 10.5220/0013697400004670.
- [14] P. Kumar, P. Singh, and S. Rana, "Gold Price Prediction Using Machine Learning Techniques," 2024. [Online]. Available: www.ijraset.com
- [15] Yimi. Diantoro, *Emas : investasi & pengolahannya : pengolahan emas skala home industry*, vol. 3. Gramedia Pustaka Utama, 2010.
- [16] F. M. Aragon and J. P. Rud, "Natural Resources and Local Communities: Evidence from a Peruvian Gold Mine," *Am Econ J Econ Policy*, vol. 5, no. 2, pp. 1–25, 2013.
- [17] S. Das, J. Nayak, B. Kamesh Rao, K. Vakula, and A. Ranjan Routray, "Gold Price Forecasting Using Machine Learning Techniques: Review of a Decade," 2022, pp. 679–695. doi: 10.1007/978-981-16-2543-5_58.
- [18] W. Hamzan, *Prediksi Harga Emas dengan Jaringan Saraf Tiruan Backpropagation*. 2022.
- [19] Marina and A. D. Lestari Ida, "Pentingnya Data Deret Waktu dalam Melakukan Perencanaan Produksi (The Importance of Time Series Data in Production Planning)," *Seminar Nasional Multi Disiplin Ilmu dan Call for Papers*, no. 2011, 2017.
- [20] G. A. M. A. Putri, N. P. N. Hendayanti, and M. Nurhidayati, "PEMODELAN DATA DERET WAKTU DENGAN AUTOREGRESSIVE INTEGRATED MOVING AVERAGE DAN LOGISTIC SMOOTHING TRANSITION AUTOREGRESSIVE," *Jurnal Varian*, vol. 1, no. 1, 2017, doi: 10.30812/varian.v1i1.50.

- [21] Sunaryo, “Determinan Harga Emas (Studi Kasus pada PT Aneka Tambang, Tbk. Periode Tahun 2010 - 2019),” *KINERJA Jurnal Ekonomi dan Bisnis*, vol. 5, no. 1, 2022.
- [22] J. Han, M. Kamber, and J. Pei, “Data Mining. Concepts and Techniques, 3rd Edition (The Morgan Kaufmann Series in Data Management Systems),” 2011.
- [23] D. Cahya and P. Buani, “Deteksi Dini Penyakit Diabetes dengan Menggunakan Algoritma Random Forest,” *Jurnal Sains dan Manajemen*, vol. 12, no. 1, 2024.
- [24] D. Ramdhan, G. Dwilestari, R. Danar Dana, and A. Ajiz, “Clustering Data Persediaan Barang dengan Menggunakan Metode K-Means. Clustering Data Persediaan Barang dengan Menggunakan Metode K-Means,” vol. 7, no. 1, [Online]. Available: http://ejournal.ust.ac.id/index.php/Jurnal_Means/
- [25] S. Thomas, G. N. Pillai, and K. Pal, “Prediction of peak ground acceleration using ϵ -SVR, ν -SVR and Ls-SVR algorithm,” *Geomatics, Natural Hazards and Risk*, vol. 8, no. 2, 2017, doi: 10.1080/19475705.2016.1176604.
- [26] I. M. Gananta, I. N. Purnama, and K. Queena Fredlina, “OPTIMASI PREDIKSI HARGA EMAS DENGAN METODE SUPPORT VECTOR REGRESSION (SVR) MENGGUNAKAN ALGORITMA GRID SEARCH,” *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 7, no. 6, 2024, doi: 10.36040/jati.v7i6.8000.
- [27] J. J. Faraway, *Extending the Linear Model with R: Generalized Linear, Mixed Effects and Nonparametric Regression Models, Second Edition*. 2016. doi: 10.1201/9781315382722.
- [28] A. Kelemen, Z. K. Szabó, S. Bozóki, Z. Szádóczki, and Á. D. Hartvig, “A sensitivity analysis of composite indicators: Min/max thresholds,” *Environmental and Sustainability Indicators*, vol. 23, 2024, doi: 10.1016/j.indic.2024.100453.
- [29] H. Aissi, C. Bazgan, and D. Vanderpooten, “Min-max and min-max regret versions of combinatorial optimization problems: A survey,” *Eur J Oper Res*, vol. 197, no. 2, 2009, doi: 10.1016/j.ejor.2008.09.012.
- [30] J. Ungredda and J. Branke, “Bayesian Optimisation for Constrained Problems,” *ACM Transactions on Modeling and Computer Simulation*, vol. 34, no. 2, 2024, doi: 10.1145/3641544.

- [31] S. Amini, I. Vannieuwenhuyse, and A. Morales-Hernandez, “Constrained Bayesian Optimization: A Review,” 2025. doi: 10.1109/ACCESS.2024.3522876.
- [32] D. I. Purnama, “Peramalan Harga Emas Saat Pandemi Covid-19 Menggunakan Model Hybrid Autoregressive Integrated Moving Average - Support Vector Regression,” *Jambura Journal of Mathematics*, vol. 3, no. 1, 2021, doi: 10.34312/jjom.v3i1.8430.
- [33] B. Putra and A. H. Muhammad, “Prediksi Prevalensi Stunting di Indonesia dengan Ordinary Least Square (OLS),” *G-Tech: Jurnal Teknologi Terapan*, vol. 8, no. 3, 2024, doi: 10.33379/gtech.v8i3.4623.
- [34] G. N. Lesnusa, Dwi Shinta Angreni, and R. Ardiansyah, “PERBANDINGAN AKURASI LINEAR REGRESSION DAN SUPPORT VECTOR REGRESSION DALAM PREDIKSI SUHU RATA-RATA,” *The Indonesian Journal of Computer Science*, vol. 13, no. 4, 2024, doi: 10.33022/ijcs.v13i4.3944.
- [35] F. E. Penalun, A. Hermawan, and D. Avianto, “Perbandingan Random Forest Regression dan Support Vector Regression Pada Prediksi Laju Penguapan,” *JURNAL FASILKOM*, vol. 13, no. 02, 2023, doi: 10.37859/jf.v13i02.4976.
- [36] Streamlit, “Streamlit Documentation,” *Streamlit Inc.*, 2022.
- [37] Y. Akkem, B. S. Kumar, and A. Varanasi, “Streamlit Application for Advanced Ensemble Learning Methods in Crop Recommendation Systems – A Review and Implementation,” *Indian J Sci Technol*, vol. 16, no. 48, 2023, doi: 10.17485/ijst/v16i48.2850.
- [38] C. Nantasenamat, “Building a dashboard in Python using Streamlit,” 2024.